LANGKAH 01 / PANDUAN INTI

# Satu jalur belajar, dari awal sampai sidang

Ikuti PDF ini berurutan. Setelah satu tahap paham, buka notebook yang diarahkan. Kamu nggak perlu membaca semua folder sekaligus.

**Cerita penelitianmu**
Struktur **satu molekul** → fitur angka → model untuk tiap label → skor → beberapa label aroma. Model belajar mencocokkan fitur dengan **anotasi yang tercatat**, bukan mencium molekul secara langsung.


| Urutan baca | Halaman |
|---|---|
| Alasan ilmiah, gap, dan kontribusi penelitian | 2-3 |
| Penelitian terdahulu, pilihan model, dan batas tanpa RF | 4-6 |
| Dataset, preprocessing, fitur, dan pembagian data | 7-10 |
| Model, bobot kelas, training, dan tuning | 11-13 |
| CV, lima seed, dan OOF | 14-15 |
| Hitungan evaluasi: confusion matrix sampai AUROC | 16-18 |
| Threshold tambahan dan hasil asli | 19-20 |
| Prediksi, sumber rujukan, dan latihan sidang | 21-22 |


## Pola belajar yang dipakai

Mulai dari dasar ilmiah di halaman 2-3 dan alasan pemilihan model di halaman 5-6, lalu masuk ke metode. Baca satu halaman → kerjakan contoh tanpa melihat jawaban → buka bagian notebook yang disebut → jelaskan lagi dengan kalimatmu sendiri. Kalau masih bingung, berhenti di tahap itu dulu.

**Angka ilustrasi** di kotak latihan dibuat kecil supaya bisa dihitung manual. Rumus dan aturannya mengikuti implementasi. **Hasil asli** diberi tanda dan berasal dari artefak utama yang dikunci.

## Cukup tiga pintu masuk

**PDF ini** untuk alur dan rumus; **notebook 01-08** untuk kode lengkap; **04_Hasil/comparison_all.csv** untuk hasil delapan kandidat. 01_Materi adalah bacaan pendalaman opsional.

Notebook sudah berisi output. Kamu boleh membacanya tanpa menjalankan sel. Menjalankan notebook dapat menghitung fitur, audit, atau inferensi; gerbang eksperimen penuh pada notebook 07 tetap False. Jangan diaktifkan hanya untuk belajar.

Diperiksa 3 November 2026 terhadap laporan utama dan source aktual. Hasil utama: arsip perfume-five-grouped-v7-m2048-d8. Nama arsip bukan nama metode.

LANGKAH 02 / PANDUAN INTI

# Mengapa topik ini layak diteliti?

Alasan utamanya adalah masalah ilmiah yang bisa diuji: bagaimana memetakan struktur molekul menjadi beberapa label aroma, dan informasi fitur apa yang membantu prediksinya?

## 1. Struktur tersedia, tetapi hubungan dengan aroma tidak sederhana

Saini dan Ramanathan [1] meneliti prediksi aroma dari struktur sebagai masalah multi-label. Artinya, tugasnya bukan mencocokkan satu molekul dengan satu kelas saja. Penelitianmu menguji apakah pola struktur dan sifat numerik molekul dapat dipakai memeringkat beberapa anotasi aroma dengan baik.

## 2. Ada data untuk belajar, sekaligus masalah yang perlu dikendalikan

Hamel dkk. [2] memperkenalkan Pyrfume untuk mengintegrasikan data olfaksi yang tersebar. Ketersediaan data membuka peluang pemodelan, tetapi tidak otomatis membuat anotasi seragam atau evaluasi dapat dibandingkan.

| Masalah pada penelitianmu | Mengapa penting secara ilmiah |
|---|---|
| Istilah dan anotasi tidak seragam | Penyelarasan menentukan target yang dipelajari. Target nol belum membuktikan aroma tidak ada. |
| Dukungan label tidak seimbang | Model perlu dinilai dari kemampuan menemukan positif; accuracy saja bisa menyesatkan. |
| Identitas/fitur molekul dapat berulang | Pemisahan kelompok diperlukan agar representasi identik tidak tersebar ke fitting dan evaluasi. |

## 3. Pertanyaannya spesifik, bukan sekadar “membuat prediksi aroma”

**Apakah delapan deskriptor fisikokimia melengkapi Morgan fingerprint, dan bagaimana respons dua algoritma boosting terhadap tambahan fitur serta tuning?** Morgan merangkum pola lokal, sedangkan deskriptor memberi ringkasan sifat molekul. Manfaat penggabungannya harus diuji; lebih banyak fitur belum tentu lebih baik.

**Alasan ilmiah dalam satu kalimat**

“Saya meneliti manfaat tambahan informasi fisikokimia dan tuning untuk prediksi aroma multi-label berbasis struktur, melalui perbandingan kandidat pada data dan pembagian kelompok yang sama.”

**[1]** Saini & Ramanathan (2022), *Predicting odor from molecular structure: a multi-label classification approach*. doi:10.1038/s41598-022-18086-y.
**[2]** Hamel dkk. (2024), *Pyrfume: A window to the world’s olfactory data*. doi:10.1038/s41597-024-04051-z. Masalah data pada tabel dirujuk ke audit proyek serta Bab1/Bab3 laporan utama.

LANGKAH 03 / PANDUAN INTI

# Gap yang ditindaklanjuti dan kontribusi skripsimu

Gap berarti pertanyaan yang belum dijawab oleh eksperimen acuan yang kamu telaah. Ini tidak otomatis berarti belum pernah ada satu pun penelitian serupa di dunia.

## Dari acuan menjadi pertanyaan penelitian sendiri

Suh dkk. [3] mengevaluasi Morgan, delapan deskriptor, dan gugus fungsi sebagai representasi terpisah. Eksperimen tersebut belum langsung menjawab manfaat **menambahkan paket delapan deskriptor ke Morgan** pada kohor dan protokol penelitianmu.

| Yang ingin diketahui | Cara mengujinya |
|---|---|
| Apakah deskriptor melengkapi Morgan? | B-A: tambahan fitur pada baseline tetap. D-C: hasil gabungan setelah tuning terpisah. |
| Apakah tuning membantu? | C-A dan D-B: representasi tetap, pengaturan model berbeda. |
| Apakah temuan stabil pada pembagian train? | Lima pengulangan grouped CV memakai pembagian label-seed yang sama antarkandidat. Ini bukan nested CV. |

Perbandingan dalam data yang sama diperlukan supaya selisih skor tidak sekadar berasal dari perbedaan kohor, kosakata label, atau split. Kontribusinya adalah **bukti empiris internal tentang fitur dan tuning**, bukan penciptaan algoritma baru atau pembuktian paling unggul atas semua model.

## Contoh jawaban sidang: “Mengapa memilih topik ini?”

**Mulai dari masalah ilmiah, lanjutkan ke pertanyaan yang diuji**
“Prediksi struktur-aroma merupakan masalah multi-label, dan pilihan representasi dapat memengaruhi kemampuan model menemukan label positif. Saya menindaklanjuti eksperimen representasi terpisah pada Suh dengan menguji Morgan yang ditambah delapan deskriptor, serta pengaruh tuning pada dua algoritma boosting. Kontribusi saya adalah perbandingan terkontrol dalam dataset penelitian, disertai implementasi model terpilih pada aplikasi. Hasilnya tetap dibatasi kualitas anotasi dan protokol evaluasi yang digunakan.”

## Lalu, kegiatan meracik parfum ditempatkan di mana?

Itu **motivasi penerapan dan pemicu ide pribadi**: informasi awal aroma per senyawa berstruktur diketahui dapat menjadi bahan pertimbangan sebelum uji racik. Video TikTok yang kamu ceritakan memberi konteks tersebut; manfaat bagi peracik belum diuji, dan aroma akhir campuran bukan keluaran model.

**[3]** Suh, Hong & Park (2025), *A comparative study of machine learning models on molecular fingerprints for odor decoding.* doi:10.1038/s42004-025-01651-7. Gap/kontribusi mengikuti Bab1, Bab2, dan Bab5 laporan utama. Narasi ini memperjelas posisi studi terhadap acuan yang ditelaah, bukan tinjauan sistematis seluruh literatur.

LANGKAH 04 / PANDUAN INTI

# Apa yang ingin dijawab skripsimu?

Pertanyaannya: seberapa baik XGBoost dan LightGBM memprediksi beberapa label aroma dari fitur struktur molekul, dan apa pengaruh tambahan fitur serta tuning?

## Penelitian terdahulu memberi pijakan

| Acuan di Bab II | Yang kamu ambil dari konteksnya |
|---|---|
| Keller dkk. (2017) | Struktur kimia dapat dipakai untuk memodelkan atribut persepsi aroma. |
| Saini & Ramanathan (2022) | Satu molekul bisa punya banyak label; Binary Relevance adalah salah satu pendekatannya. |
| Tyagi dkk. (2024) | Memberi konteks pemanfaatan informasi fisikokimia. Data dan metriknya berbeda. |
| Suh dkk. (2025) | Membandingkan representasi serta algoritma. Delapan deskriptor, Morgan, dan gugus fungsi diuji sebagai representasi terpisah. |

**Posisi penelitianmu:** menguji Morgan saja dan Morgan + delapan deskriptor, dengan/tanpa Optuna, untuk dua algoritma pada dataset serta pembagian kelompok yang sama. Gabungan Morgan + 8 adalah eksperimen proyekmu, bukan konfigurasi gabungan yang diklaim menyalin Suh.

## Empat kondisi untuk setiap algoritma

| Kondisi | Masukan | Pengaturan |
|---|---|---|
| A | Morgan: 2.048 fitur | Baseline 100 pohon |
| B | Morgan + 8: 2.056 fitur | Baseline 100 pohon |
| C | Morgan: 2.048 fitur | Hasil tuning Optuna |
| D | Morgan + 8: 2.056 fitur | Hasil tuning Optuna |

**B-A** menilai tambahan deskriptor pada baseline tetap. **C-A** dan **D-B** menilai hasil tuning. **D-C** juga melibatkan parameter terbaik yang mungkin berbeda, jadi bukan efek fitur murni.

**Kalau dosen bertanya kontribusinya**
"Saya menguji manfaat dan keterbatasan penggabungan fitur serta tuning melalui delapan kandidat pada data yang sama, kemudian mengintegrasikan model terpilih ke Essenza."

Rujukan: laporan utama Bab2, "Penelitian Terdahulu"; Bab3, "Rancangan Penelitian". Baca 05_Referensi jika ingin mendalami paper. Skor antarpenelitian tidak dibandingkan langsung karena data, label, split, dan metrik berbeda.

LANGKAH 05 / PANDUAN INTI

# Mengapa XGBoost dan LightGBM?

Dasarnya terdiri dari dukungan empiris di penelitian aroma, kesesuaian dengan fitur molekul, dan perbedaan implementasi boosting yang layak dibandingkan.

## 1. Ada dukungan domain yang langsung relevan

Pada **Morgan/ST**, Table 2 Suh [3] melaporkan hasil test berikut. Ini angka penelitian Suh, bukan hasil skripsimu dan bukan ukuran yang langsung dapat dibandingkan dengan skor skripsi.

| Model pada Morgan | AUROC Suh | AUPRC Suh |
|---|---|---|
| XGBoost | 0,828 | 0,237 |
| LightGBM | 0,810 | 0,228 |
| Random Forest | 0,784 | 0,216 |

XGBoost dan LightGBM berada di atas RF menurut dua metrik ranking tersebut. Ini mendukung pemilihan kandidat untuk ditelaah lebih lanjut. Namun RF mempunyai precision lebih tinggi daripada LightGBM pada tabel yang sama (0,279 vs 0,215); jangan menyebut RF kalah pada semua metrik.

## 2. Cocok untuk fitur, tetapi cara tumbuhnya berbeda

Vektor Morgan dan deskriptor adalah fitur numerik. Boosting pohon dapat membentuk aturan nonlinier serta interaksi fitur dan dipakai sebagai classifier biner per label. Perbedaan berikut relevan pada konfigurasi proyek [4-6].

| Aspek | XGBoost proyek | LightGBM proyek |
|---|---|---|
| Pertumbuhan pohon | Depthwise: prioritas simpul lebih dekat akar; default versi 2.1.4. | Leaf-wise: prioritas daun dengan perbaikan loss terbesar. |
| Kendali kompleksitas | Antara lain max_depth, min_child_weight, gamma, L1/L2. | Antara lain num_leaves, max_depth, min_child_samples, L1/L2. |
| Pencarian split | Histogram: tree_method=hist. | Histogram pada GBDT. |

Kendali kompleksitas membatasi kerumitan model; **loss** adalah nilai kesalahan yang dioptimalkan. Karena cara tumbuh dan kendalinya berbeda, respons kedua model terhadap fitur dan tuning perlu diuji. RF juga sesuai untuk fitur ini, sehingga kesesuaian masukan bukan alasan menolaknya.

**[4]** Chen & Guestrin (2016), *XGBoost: A Scalable Tree Boosting System*.
**[5]** Parameter resmi XGBoost v2.1.4, grow_policy/tree_method.
**[6]** Dokumentasi resmi LightGBM 4.6, Features, histogram dan leaf-wise. Cocok dengan training.py/config proyek. GOSS tidak dinyatakan dipakai; tidak ada klaim kecepatan universal.

LANGKAH 06 / PANDUAN INTI

# Mengapa Random Forest tidak ikut dibandingkan?

Alasan yang dapat dipertanggungjawabkan adalah fokus perbandingan, dengan batas klaim yang jelas. Tidak ada eksperimen RF pada dataset proyek yang membuktikan RF lebih buruk.

## Fokus studi: dua implementasi gradient boosting

Bab1 menjelaskan pilihan XGBoost dan LightGBM sebagai boosting pohon dengan pertumbuhan serta kendali kompleksitas berbeda. Dengan fokus itu, eksperimen A-D menguji tambahan fitur dan tuning pada dua implementasi boosting. Menyalin semua algoritma Suh tidak menjadi syarat agar pertanyaan yang lebih sempit ini dapat diuji.

| Keluarga metode | Apa yang dibangun |
|---|---|
| Random Forest [7] | Pohon dengan randomisasi data/fitur yang digabung sebagai ensemble; keluarga bagging/randomized trees. |
| XGBoost dan LightGBM | Ensemble bertahap: pohon berikutnya memperbaiki objective model gabungan; keluarga gradient boosting. |

Memasukkan RF akan menambah pembanding lintas keluarga yang bernilai. Jika A-D juga diterapkan pada RF, rancangan menjadi 12 kandidat. Namun jumlah kandidat yang lebih sedikit bukan bukti bahwa RF tidak perlu secara universal; pembatasan mengikuti pertanyaan studi, bukan penolakan kelayakan RF.

## Konsekuensi yang perlu kamu akui

**Baseline A/B** adalah pembanding konfigurasi dalam XGBoost/LightGBM, bukan pengganti baseline RF. Tanpa RF pada data sendiri, belum diketahui apakah RF dapat mengungguli model terpilih. Kesimpulan hanya berlaku pada delapan kandidat yang diuji; tidak ada kesimpulan “boosting lebih baik daripada bagging”.

**Contoh jawaban sidang: “Mengapa RF pada Suh tidak dipakai?”**
“Saya mempersempit ruang lingkup ke dua implementasi gradient boosting untuk menguji fitur dan tuning. Pemilihannya didukung hasil Morgan pada Suh serta perbedaan cara tumbuh dan kendali kompleksitas. RF tetap pembanding yang valid, tetapi berada di luar perbandingan ini. Karena tidak saya uji pada dataset sendiri, saya tidak menyimpulkan XGBoost atau LightGBM lebih baik daripada RF dalam penelitian saya.”

**Status alasan:** Bab1 mengaitkan pemilihan dua model dengan sifat boosting serta perbedaan pertumbuhan dan kendali kompleksitas. Hasil Suh diperiksa sebagai dukungan ilmiah pada revisi ini, bukan bukti alasan historis awal. Tidak ditemukan catatan RF dikeluarkan setelah gagal pada data proyek.

**[7]** Breiman (2001), *Random Forests*, bagian 1 dan 3.1. Paper primer penulis. Fokus eksperimen: Bab1/Bab3 laporan utama, experiment.py: ALGORITHMS dan CANDIDATES. RF layak diusulkan sebagai perluasan pembandingan.

LANGKAH 07 / PANDUAN INTI

# Dataset itu isinya apa?

Satu baris akhir mewakili satu molekul. Kolom masukan menggambarkan strukturnya; kolom target menunjukkan label aroma yang tercatat.

## Lima sumber melalui Pyrfume

| Sumber | Bentuk catatan aroma |
|---|---|
| GoodScents | Teks deskriptor |
| IFRA 2019 | Tiga kolom deskriptor; sumber kamus target |
| Leffingwell | Indikator biner deskriptor |
| Arctander 1960 | Teks label aroma |
| Sigma-Aldrich 2014 | Indikator biner aroma |

Catatan aroma dan struktur bisa berada di tabel berbeda. **Stimulus** mengidentifikasi stimulus pada sumber; **CID** adalah pengenal senyawa PubChem; **CAS** adalah pengenal registrasi senyawa. Kode menyambungkan identitas yang tersedia, bukan menyamakan posisi baris.

**Ilustrasi join, bukan baris dataset asli**
Tabel anotasi: Stimulus S1 → floral. Tabel penghubung: S1 → CID 123. Tabel molekul: CID 123 → SMILES. Setelah join, anotasi floral terhubung ke struktur itu. Angka 123 hanya pengenal ilustrasi, bukan identitas molekul yang diverifikasi.

## Bentuk akhir hasil kurasi - angka asli

| Bagian | Jumlah molekul | Target |
|---|---|---|
| Train | 5.353 | 109 kolom label |
| Test | 1.333 | 109 kolom label |
| Total | 6.686 | Satu baris bisa punya banyak label |

**X** adalah matriks fitur masukan; **Y** adalah matriks target. Untuk model D, X train berukuran 5.353 × 2.056 dan Y train 5.353 × 109. Tanda × berarti jumlah baris dikali jumlah kolom, bukan jumlah kelas baru.

## Buka notebook setelah konsepnya nyambung

**01_Sumber_Data.ipynb**
Konfigurasi sumber → Baca snapshot dan ukur tabel → Ikuti contoh join GoodScents

Mulai dari bagian Persiapan saat membuka notebook mandiri. Cari judul di atas dengan Ctrl+F; baca penjelasan, source, lalu output tepat di bawahnya.

Rujukan: Bab3: Akuisisi dan Kurasi Data; 03_Kode/preprocessing.py dan source_identity.py. Data belajar: 02_Data/README.md.

LANGKAH 08 / PANDUAN INTI

# Preprocessing: merapikan tanpa menebak

Tujuannya memastikan struktur valid, identitas cocok, dan istilah aroma masuk ke kosakata yang sama sebelum model belajar.

| Urutan | Yang dilakukan dan alasannya |
|---|---|
| 1. Cocokkan identitas | Hubungkan anotasi dan struktur lewat pengenal yang dapat diverifikasi. |
| 2. Periksa struktur | Tolak struktur kosong, tidak valid, atau multifragmen. Tidak mengisi SMILES kosong dengan imputasi dan tidak otomatis memilih fragmen terbesar. |
| 3. Selaraskan istilah | Normalisasi huruf/tanda baca/spasi; cocokkan langsung atau lewat alias eksplisit. Tolak baris tanpa label terpetakan; tidak memakai fuzzy matching. |
| 4. Kanonisasi dan gabung | Samakan penulisan SMILES; gabungkan hanya SMILES kanonik identik. Satukan himpunan label dan simpan asal anotasi. |
| 5. Bentuk target | Setelah pembagian awal, pilih label dengan ≥30 positif dan ≥2 negatif pada train. Hasilnya 109 label. |

Kanonisasi bukan berarti semua stereoisomer, tautomer, dan bentuk protonasi disatukan. Struktur stereokimia masih dicatat; fitur Morgan yang dipakai justru tidak memasukkan chirality.

## Contoh aturan label yang benar-benar ada

**jasmine** → **jasmin** adalah salah satu alias. **tropical** → **tropical fruit** juga ada, tetapi perubahan makna ini perlu tinjauan ahli; jangan menyebut semua alias pasti benar secara sensori.

**Tiga angka yang beda fungsi**
**184** istilah kamus IFRA; **31** aturan alias; **109** target model setelah seleksi dukungan train. Ini bukan tiga versi jumlah kelas yang bisa dipertukarkan.

**Hasil audit asli:** 6.494 kemunculan istilah dari 498 bentuk tidak terpetakan; 3.898 baris sumber yang diterima tetap kehilangan sebagian token. Setelah seleksi target, 11 baris train dan 4 test seluruhnya nol, dan tetap dipertahankan.

**Target 1** = label tercatat; **target 0** = tidak tercatat. Nol belum membuktikan molekul tidak beraroma tersebut.

## Buka notebook setelah konsepnya nyambung

**02_Preprocessing_dan_Audit_Label.ipynb**
normalize → taxonomy_from_ifra → tokens_for → map_labels → merge_sources → Buktikan asal angka 109 → Rekonsiliasi jumlah baris dan token

Mulai dari bagian Persiapan saat membuka notebook mandiri. Cari judul di atas dengan Ctrl+F; baca penjelasan, source, lalu output tepat di bawahnya.

Rujukan: Bab3: Harmonisasi dan Encoding Label; 03_Kode/preprocessing.py; 06_Audit_Label/summary.json.

LANGKAH 09 / PANDUAN INTI

# Fingerprint dan deskriptor: struktur menjadi angka

Model tidak langsung membaca huruf SMILES. RDKit lebih dulu mengubah struktur molekul menjadi fitur numerik.

## Morgan: pola di sekitar atom

**Radius 2** berarti menjangkau lingkungan lokal sampai dua ikatan dari atom pusat. Lingkungan dipetakan lewat hashing ke **2.048 posisi bit**. Nilai 1 berarti ada pola yang terpetakan ke posisi itu; 0 berarti posisi itu tidak terisi. Satu bit bisa menerima beberapa pola berbeda: ini disebut collision.

**Ilustrasi sederhana, bukan hasil hashing RDKit**
Pola A dan pola B sama-sama masuk posisi ke-3; posisi itu tetap bernilai 1. Vektor kecil [0, 0, 1, 0] hanya membantu memahami collision. Model asli memakai 2.048 bit, bukan 4 bit.

**includeChirality=False** berarti ciri kiral tidak disertakan pada fingerprint. Molekul yang berbeda stereokimia dapat memiliki fitur sama. Audit menemukan 1.474 molekul berada dalam kelompok fitur identik tetapi targetnya berbeda; ini batas representasi/anotasi, bukan otomatis kesalahan semua molekul tersebut.

## Delapan angka pelengkap, dalam urutan aktual

| Deskriptor | Yang diringkas |
|---|---|
| MolWt / MolLogP | Massa molekul relatif / estimasi lipofilisitas |
| NumHDonors / NumHAcceptors | Jumlah donor / akseptor ikatan hidrogen |
| TPSA | Luas permukaan polar topologis |
| NumRotatableBonds | Jumlah ikatan yang dapat berotasi menurut RDKit |
| HeavyAtomCount / RingCount | Jumlah atom selain H / jumlah cincin menurut RDKit |

A/C memakai 2.048 fitur; B/D memakai 2.048 + 8 = **2.056 fitur**. Masukan akhirnya float32; deskriptor tidak distandardisasi atau dinormalisasi skalanya pada pipeline ini. Nilai tidak finite menghentikan proses.

**Bit fitur 0/1 berbeda dengan target aroma 0/1.** Bit adalah masukan pola struktur; target adalah jawaban anotasi yang ingin dipelajari.

## Buka notebook setelah konsepnya nyambung

**03_Dataset_dan_Fitur.ipynb**
calculate_morgan → calculate → features → Lihat satu molekul yang memang ada dalam data

Mulai dari bagian Persiapan saat membuka notebook mandiri. Cari judul di atas dengan Ctrl+F; baca penjelasan, source, lalu output tepat di bawahnya.

Rujukan: Bab2: Representasi Molekul; Bab3: Ekstraksi Fitur; 03_Kode/features.py. Temuan fitur identik: 04_Hasil/audit_27_oktober/README.md.

LANGKAH 10 / PANDUAN INTI

# Train, test, dan fold: siapa dipakai untuk apa?

Pisahkan tiga peran: data untuk belajar model, data validasi untuk menilai pilihan, dan data test untuk evaluasi akhir setelah keputusan dikunci.

| Bagian | Peran dalam penelitian |
|---|---|
| Train: 5.353 molekul | Sumber fitting dan validasi silang untuk tuning serta seleksi kandidat. |
| Validation fold | Bagian dari train yang sementara ditahan saat satu model fold belajar. |
| Test: 1.333 molekul | Dievaluasi setelah resep, pilihan kandidat, dan threshold dibekukan pada run utama. |

## Kenapa menggunakan kelompok?

Struktur identik tanpa stereo atau Morgan **1.024 bit identik** dihubungkan secara transitif menjadi kelompok historis. Kalau A terhubung ke B dan B ke C, ketiganya satu kelompok. Anggota satu kelompok harus berada pada sisi pembagian yang sama.

Fingerprint 1.024 di sini dipakai untuk **asal kelompok**, bukan fitur training utama. Model utama tetap Morgan 2.048. Kelompok beku dipakai kembali supaya delapan kandidat dibandingkan pada pemisahan yang sama.

**Ilustrasi kelompok**
Misal A dan B satu grup. Jika A masuk train, B tidak boleh masuk test. Saat train dibagi menjadi fold, keduanya juga tidak boleh terpisah antara fitting dan validation pada fold yang sama.

## Lima fold berarti lima giliran

Bayangkan bagian train dikelompokkan menjadi lima bagian. Giliran 1: empat bagian untuk fitting, satu bagian untuk validasi. Giliran berikutnya: bagian yang ditahan berganti. Model tiap giliran dilatih dari awal, bukan melanjutkan model sebelumnya.

Implementasi memakai **GroupShuffleSplit** untuk train-test dan **StratifiedGroupKFold per label** untuk fold. Jadi jangan menganggap satu tabel fold berlaku bersama untuk seluruh label. Fold label-seed yang sama digunakan seluruh kandidat.

Aturan ini mencegah irisan kelompok yang didefinisikan protokol, bukan seluruh kemiripan molekul atau scaffold. Test pernah dilihat dalam pengembangan sebelumnya; hasil tetap eksploratori.

## Buka notebook setelah konsepnya nyambung

**04_Grup_Split_dan_Fold.ipynb**
Bedakan pembentukan historis dengan pemakaian saat ini → structure_feature_groups → outer_split → inner_folds → Contoh pembagian satu label

Mulai dari bagian Persiapan saat membuka notebook mandiri. Cari judul di atas dengan Ctrl+F; baca penjelasan, source, lalu output tepat di bawahnya.

Rujukan: Bab3: Pembagian Data dan Validasi; asal_kohor.py; 03_Kode/splits.py.

LANGKAH 11 / PANDUAN INTI

# 109 classifier, bukan 109 pohon

Binary Relevance memisahkan tugas multi-label menjadi 109 masalah biner. Setiap classifier mempelajari satu kolom target dan berisi banyak pohon.

## Model belajar apa?

Classifier floral menerima fitur molekul dan target floral 0/1. Classifier woody menerima fitur yang sama, tetapi target woody 0/1. Hubungan antarlabel tidak dipelajari secara eksplisit oleh Binary Relevance.

**Boosting** menambahkan pohon bertahap untuk memperbaiki prediksi ensemble. Pohon menyumbang nilai numerik ke model gabungan; keluaran bukan voting mayoritas label dari seluruh pohon. Proses optimasinya dikerjakan pustaka XGBoost/LightGBM.

| Algoritma | Perbedaan yang perlu kamu pegang |
|---|---|
| XGBoost | Boosting pohon dengan pengendalian kedalaman, regularisasi, dan aturan split; proyek menggunakan tree_method=hist. |
| LightGBM | Boosting dengan pertumbuhan leaf-wise: memilih daun dengan perbaikan terbaik. num_leaves dan batas data pada daun mengendalikan kompleksitas. |

## Rumus keputusan label - Bab II

$$\hat{y}_{ij} = I(p_{ij} \geq t_j)$$

**i**: molekul; **j**: label; $\mathbf{p_{ij}}$: skor positif; $\mathbf{t_j}$: threshold; $\hat{\mathbf{y}}_{\mathbf{ij}}$: keputusan prediksi. **I(kondisi)** bernilai 1 jika kondisi benar, selain itu 0. Tanda ≥ berarti lebih besar atau sama dengan.

| Ilustrasi satu molekul | Skor | t = 0,50 | Keputusan |
|---|---|---|---|
| floral | 0,72 | 0,72 ≥ 0,50 | 1 |
| woody | 0,50 | 0,50 ≥ 0,50 | 1 |
| sweet | 0,20 | 0,20 < 0,50 | 0 |

Jumlah skor tidak harus 1 karena ini banyak label biner. Skor 0,72 bukan akurasi 72%, intensitas 72%, atau peluang manusia yang sudah terkalibrasi.

## Buka notebook setelah konsepnya nyambung

**05_Model_dan_Bobot.ipynb**
training.make_model → Periksa delapan recipe aktual → Periksa model final yang sudah ada

Mulai dari bagian Persiapan saat membuka notebook mandiri. Cari judul di atas dengan Ctrl+F; baca penjelasan, source, lalu output tepat di bawahnya.

Rujukan: Bab2: eq:label_threshold; 03_Kode/training.py. Pengambilan skor: 03_Kode/inference.py.

LANGKAH 12 / PANDUAN INTI

# Bobot kelas: positif yang langka diperhatikan

Kalau label jarang tercatat, model bisa lebih mudah mengejar keputusan negatif. Pembobotan memberi pengaruh lebih besar pada sampel dari kelas yang lebih sedikit.

## Rumus yang benar-benar dipakai - Bab II

$$w_c = N / (2 \times N_c)$$

**c** adalah kelas 0 atau 1; **N** jumlah sampel pada bagian fitting; $\mathbf{N_c}$ jumlah sampel kelas c pada bagian itu; $\mathbf{w_c}$ bobot yang diberikan kepada setiap sampel kelas c. Angka 2 berasal dari dua kelas biner.

**Ilustrasi satu label dalam satu training fold**
Ada 10 molekul: 2 positif dan 8 negatif. Ini angka latihan, bukan jumlah kelas dari eksperimen asli.

| Langkah | Hitungan |
|---|---|
| 1. Bobot positif | $w_1 = 10 / (2 \times 2) = 2{,}5$ |
| 2. Bobot negatif | $w_0 = 10 / (2 \times 8) = 0{,}625$ |
| 3. Total bobot positif | 2 sampel × 2,5 = 5 |
| 4. Total bobot negatif | 8 sampel × 0,625 = 5 |

Total pengaruh bobot tiap kelas menjadi seimbang. **Jumlah baris tetap 10**; tidak ada penggandaan sampel dari rumus ini. Bobot masuk ke fit melalui sample_weight.

## Bobotnya dihitung dari bagian mana?

Saat CV: hanya bagian fitting fold yang sedang dipakai. Saat final fit: seluruh 5.353 data train, per label. Tidak menggunakan label validation atau test untuk menentukan bobot.

**Jawaban singkat untuk dosen**
"Saya memakai aturan bobot yang sama pada kedua algoritma. Bobot dihitung ulang hanya dari data fitting agar tidak mengambil informasi kelas dari validation atau test."

Ini alasan teknis pemakaian bobot. Penelitian tidak menguji kondisi tanpa bobot, jadi hasilnya tidak membuktikan bahwa pembobotan mengungguli semua alternatif penanganan imbalance.

## Buka notebook setelah konsepnya nyambung

**05_Model_dan_Bobot.ipynb**
training.balanced_sample_weights → Buktikan rumus bobot pada label aktual → training.fit

Mulai dari bagian Persiapan saat membuka notebook mandiri. Cari judul di atas dengan Ctrl+F; baca penjelasan, source, lalu output tepat di bawahnya.

Rujukan: Bab2: eq:bobot_kelas_seimbang; Bab3: Model dan Optimasi Optuna; 03_Kode/training.py.

LANGKAH 13 / PANDUAN INTI

# Training dan tuning: dua pekerjaan berbeda

Training mempelajari isi pohon dari data. Tuning mencari pengaturan model, misalnya jumlah pohon dan learning rate, berdasarkan hasil validasi.

| Tahap | Input → proses → output |
|---|---|
| Baseline A/B | Fitur + target train → fit dengan 100 pohon → resep pembanding tanpa Optuna. |
| Tuning C/D | Ruang parameter → trial + CV seed 42 → resep dengan AP objective terbaik dalam anggaran. |
| Validasi berulang | Delapan resep tetap → CV lima seed → skor seleksi dan prediksi OOF. |
| Kunci keputusan | Resep + validasi + threshold → selection_frozen.json → pilihan kandidat tetap. |
| Final fit seluruh kandidat | Seluruh 5.353 train → fit dari awal per label → 109 model final tiap kandidat. |
| Evaluasi test | Model final + 1.333 test → skor dan metrik → tabel hasil akhir. |

**Satu trial** adalah satu paket parameter bersama untuk 109 classifier, dengan fitur sesuai kandidatnya. Bukan satu trial terpisah untuk tiap label. Tuning memakai empat studi: XGB C/D dan LGBM C/D, masing-masing **8 jam aktif**; total anggaran tuning 32 jam.

## Tiga pengaturan yang cukup dipahami dulu

**n_estimators:** jumlah iterasi/pohon yang diminta. **learning_rate:** besar kontribusi pembaruan. **max_depth:** batas kedalaman pohon. LightGBM juga membatasi jumlah daun lewat num_leaves. Nilai besar tidak otomatis lebih baik karena bisa memperbesar overfitting.

Trial pertama memakai resep awal. Parameter yang belum ditetapkan disampling acak sampai ada 10 trial selesai; setelah itu TPE memakai hasil sebelumnya. Tidak ada early stopping atau pruning dalam protokol ini. Trial terbaik berarti terbaik yang sempat selesai, bukan optimum global.

Final fit menggunakan seluruh train setelah pilihan dikunci. Skor test bisa berbeda dari validasi karena data dan cara penilaiannya berbeda; kenaikan test tidak membuktikan final fit menyebabkan peningkatan.

## Buka notebook setelah konsepnya nyambung

**06_Optuna_CV_dan_OOF.ipynb**
Baca kebijakan tuning → tuning.suggest → tuning.tune → Baca hasil empat studi sebenarnya

Mulai dari bagian Persiapan saat membuka notebook mandiri. Cari judul di atas dengan Ctrl+F; baca penjelasan, source, lalu output tepat di bawahnya.

Rujukan: Bab3: Model dan Optimasi Optuna; 03_Kode/tuning.py dan experiment.py. Urutan lengkap: notebook 07, experiment.run_all.

LANGKAH 14 / PANDUAN INTI

# Cara menghitung nilai validasi satu seed

Untuk tiap label, hitung AP setiap fold lalu rata-ratakan. Setelah itu, rata-ratakan hasil seluruh label. Urutan ini mengikuti implementasi.

## Rumus objective Optuna - Bab III

$$J(\theta) = (1/L) \Sigma_{j=1..L} [(1/K_j) \Sigma_{k=1..K_j} AP_{j,k}(\theta)]$$

**θ (theta)**: satu paket hiperparameter; **J**: nilai objective yang ingin diperbesar; **L**: jumlah label; **$K_j$**: jumlah fold label j; **$AP_{j,k}$**: Average Precision label j pada fold k. **Σ** berarti jumlahkan. **1/L** berarti bagi hasil penjumlahan dengan L.

Pada penelitian asli, L = 109 dan semua $K_j$ = 5. Angka AP dalam contoh berikut sengaja dibuat kecil; cara menghitung AP-nya dibahas pada halaman 17.

## Ilustrasi: dua label, masing-masing lima fold

| Label | F1* | F2* | F3* | F4* | F5* | Mean AP |
|---|---|---|---|---|---|---|
| A | 0,20 | 0,30 | 0,40 | 0,30 | 0,40 | 0,32 |
| B | 0,10 | 0,20 | 0,20 | 0,20 | 0,30 | 0,20 |

*F1-F5 pada tabel ini berarti **Fold 1-Fold 5**, bukan metrik F1-score.

**1.** Label A: (0,20 + 0,30 + 0,40 + 0,30 + 0,40) / 5 = 1,60 / 5 = **0,32**.

**2.** Label B: (0,10 + 0,20 + 0,20 + 0,20 + 0,30) / 5 = 1,00 / 5 = **0,20**.

**3.** Rata-rata antarlabel: J = (0,32 + 0,20) / 2 = **0,26**. Setiap label mempunyai bobot sama, tanpa menimbang banyaknya positif label.

**Yang sedang dibandingkan**
Optuna membandingkan J dari paket parameter yang dicoba pada fold tuning seed 42. Setelah resep ditetapkan, seleksi delapan kandidat memakai rata-rata J dari lima seed. Keduanya jangan disebut angka yang sama.

## Buka notebook setelah konsepnya nyambung

**06_Optuna_CV_dan_OOF.ipynb**
validation.cross_validate → validation.repeated_grouped_cv

Mulai dari bagian Persiapan saat membuka notebook mandiri. Cari judul di atas dengan Ctrl+F; baca penjelasan, source, lalu output tepat di bawahnya.

Rujukan: Bab3: eq:optuna_objective; 03_Kode/validation.py: cross_validate; 03_Kode/metrics.py: summarize.

LANGKAH 15 / PANDUAN INTI

# Lima seed dan OOF: jangan dicampur angkanya

Seed pembagian yang digunakan adalah 7, 21, 42, 84, dan 100. Mereka mengubah pembagian fold; random_state estimator tetap 42.

## Nilai seleksi: rata-rata lima hasil CV

$$J \text{ rata-rata} = (J_1 + J_2 + J_3 + J_4 + J_5) / 5$$

Subskrip 1-5 di sini menunjuk urutan pengulangan, bukan label. Ini penulisan sederhana dari operasi rata-rata lima seed yang dijelaskan Bab III dan dikerjakan validation.py.

**Ilustrasi lanjutan halaman 14**
Misal J lima pengulangan = 0,26; 0,28; 0,30; 0,32; 0,34. Jumlahnya 1,50. Rata-rata = 1,50 / 5 = **0,30**. Ini bukan skor validasi asli modelmu.

## Simpangan baku sampel: seberapa berubah antarseed?

$$s = \sqrt{[\ \Sigma_{r=1..R} (J_r - J \text{ rata-rata})^2 / (R - 1)\ ]}$$

**R = 5** pengulangan; **r** indeks pengulangan; **s** simpangan baku. Tanda $^2$ berarti dikalikan dirinya sendiri, dan √ adalah akar kuadrat. Kode menggunakan np.std(..., ddof=1), yaitu pembagi R-1, sesuai "simpangan baku sampel" di laporan.

**1.** Selisih dari 0,30: -0,04; -0,02; 0; 0,02; 0,04.
**2.** Kuadrat dan jumlahkan: 0,0016 + 0,0004 + 0 + 0,0004 + 0,0016 = 0,004.
**3.** Bagi 5-1 = 4: 0,004 / 4 = 0,001.
**4.** Akar: √0,001 ≈ **0,03162**.

## OOF adalah prediksi saat sampel ditahan dari fitting

Setiap molekul train mendapat satu skor OOF per seed dari model fold yang tidak melatih molekul itu. Lima skor OOF lalu dirata-ratakan per molekul-label. Contoh ilustrasi: (0,30 + 0,50 + 0,60 + 0,40 + 0,70) / 5 = **0,50**. Skor rata-rata ini dipakai memilih threshold tambahan.

**Mean AP antarfold/seed berbeda dari AP atas skor OOF gabungan.** AP melibatkan urutan skor, sehingga merata-ratakan AP dan merata-ratakan skor bukan operasi yang sama.

Lima seed × lima fold = **25 fitting-validasi per label per kandidat** pada tahap ini; Optuna dan final fit terpisah. Seed/fold berbagi data, jadi SD bukan interval kepercayaan lima dataset independen. CV ini bukan nested CV.

## Buka notebook setelah konsepnya nyambung

**06_Optuna_CV_dan_OOF.ipynb**
validation.repeated_grouped_cv → Hitung ulang ambang dari OOF tersimpan

Mulai dari bagian Persiapan saat membuka notebook mandiri. Cari judul di atas dengan Ctrl+F; baca penjelasan, source, lalu output tepat di bawahnya.

Rujukan: Bab3: Pembagian Data dan Validasi serta penjelasan objective; 03_Kode/validation.py (mean, std ddof=1, pooled OOF).

LANGKAH 16 / PANDUAN INTI

# Dari enam skor menjadi confusion matrix

Contoh latihan ini dipakai lagi sampai halaman 19. Hanya satu label dan enam molekul ilustrasi; bukan enam data eksperimen asli.

| Molekul | Target y | Skor p | Prediksi p ≥ 0,50 | Jenis |
|---|---|---|---|---|
| A | 1 | 0,90 | 1 | TP |
| B | 0 | 0,80 | 1 | FP |
| C | 1 | 0,70 | 1 | TP |
| D | 0 | 0,60 | 1 | FP |
| E | 1 | 0,40 | 0 | FN |
| F | 0 | 0,10 | 0 | TN |

**TP = 2:** positif tercatat dan diprediksi positif. **FP = 2:** tidak tercatat, tetapi diprediksi positif. **FN = 1:** positif tercatat terlewat. **TN = 1:** tidak tercatat dan diprediksi negatif. Total 2 + 2 + 1 + 1 = 6.

## Rumus di Bab II, langsung kita hitung

| Metrik dan rumus | Substitusi angka | Arti hasil |
|---|---|---|
| P = TP / (TP + FP) | 2 / (2 + 2) = 0,50 | Setengah prediksi positif cocok anotasi. |
| R = TP / (TP + FN) | 2 / (2 + 1) = 0,6667 | Dua dari tiga positif tercatat ditemukan. |
| F1 = 2TP / (2TP + FP + FN) | 4 / (4 + 2 + 1) = 0,5714 | Keseimbangan precision dan recall. |
| Accuracy = (TP + TN) / total | (2 + 1) / 6 = 0,50 | Tiga dari enam keputusan cocok. |
| Specificity = TN / (TN + FP) | 1 / (1 + 2) = 0,3333 | Satu dari tiga negatif anotasi dikenali. |

**P** adalah precision, **R** recall. F1 dihitung per label, kemudian dirata-ratakan untuk macro F1. F1 juga setara dengan 2PR/(P+R), yang dipakai kode.

Kode memberi precision/recall nol saat penyebutnya tidak ada, dan F1 nol jika P+R = 0. AUROC dan specificity dicatat tidak tersedia pada partisi satu kelas. FP/TN merujuk target anotasi, bukan kepastian sensori.

## Buka notebook setelah konsepnya nyambung

**07_Evaluasi_dan_Pemilihan.ipynb**
metrics.binary_metrics → metrics.summarize → Hitung ulang metrik delapan kandidat

Mulai dari bagian Persiapan saat membuka notebook mandiri. Cari judul di atas dengan Ctrl+F; baca penjelasan, source, lalu output tepat di bawahnya.

Rujukan: Bab2: eq:precision_recall, penjelasan F1, eq:accuracy_specificity; 03_Kode/metrics.py; validation.f1_from_metrics pada notebook 06.

LANGKAH 17 / PANDUAN INTI

# Average Precision: apakah positif ada di atas?

AP menilai ranking skor. Kita geser batas penerimaan dari skor tertinggi ke terendah, bukan hanya menilai keputusan pada threshold 0,5.

## Rumus AP satu label - Bab II

$$AP_j = \Sigma_k (R_{j,k} - R_{j,k-1}) \times P_{j,k}$$

**j**: label; **k**: titik threshold saat menuruni ranking; **P**: precision; **R**: recall. $\mathbf{R_{j,0} = 0}$. Maknanya: setiap kenaikan recall dikalikan precision pada titik itu, lalu dijumlahkan.

## Pakai lagi enam molekul pada halaman 16

| Skor ↓ | y | TP / terambil | P | R | Kenaikan R |
|---|---|---|---|---|---|
| 0,90 | 1 | 1 / 1 | 1 | 1/3 | 1/3 |
| 0,80 | 0 | 1 / 2 | 1/2 | 1/3 | 0 |
| 0,70 | 1 | 2 / 3 | 2/3 | 2/3 | 1/3 |
| 0,60 | 0 | 2 / 4 | 1/2 | 2/3 | 0 |
| 0,40 | 1 | 3 / 5 | 3/5 | 1 | 1/3 |
| 0,10 | 0 | 3 / 6 | 1/2 | 1 | 0 |

**1.** Ada tiga positif, jadi setiap satu positif baru menambah recall sebesar 1/3.
**2.** Hanya baris target 1 yang memberi kenaikan recall di contoh tanpa skor seri ini.
**3.** AP = (1/3 × 1) + (1/3 × 2/3) + (1/3 × 3/5).
**4.** AP = 1/3 + 2/9 + 1/5 = 34/45 ≈ **0,7556**.

Skor seri diproses bersama sebagai satu titik threshold. Contoh: dua molekul berskor 0,8 dengan target [1,0] mempunyai P = 1/2 dan R naik dari 0 ke 1, sehingga AP = **0,5**, bukan 1 karena kebetulan positif ditulis lebih dulu.

**AP bukan "akurasi sekian persen"**
Pada halaman 16, accuracy = 0,50, tetapi AP = 0,7556. AP menggunakan ranking skor, accuracy menggunakan keputusan. Kolom bernama auprc pada artefak proyek dihitung dengan average_precision_score, bukan luas trapesium PR.

## Buka notebook setelah konsepnya nyambung

**07_Evaluasi_dan_Pemilihan.ipynb**
metrics.binary_metrics → Hitung ulang metrik delapan kandidat

Mulai dari bagian Persiapan saat membuka notebook mandiri. Cari judul di atas dengan Ctrl+F; baca penjelasan, source, lalu output tepat di bawahnya.

Rujukan: Bab2: eq:average_precision; 03_Kode/metrics.py: average_precision_score. Jika satu label tanpa positif, AP dicatat nol.

LANGKAH 18 / PANDUAN INTI

# Macro dan AUROC: dua cara membaca ranking

Macro berarti hitung setiap label terlebih dahulu, lalu rata-ratakan dengan bobot label yang sama. Label yang sering muncul tidak mendapat bobot lebih besar.

## Rumus macro AP - Bab II

$$AP_{macro} = (1/L)\ \Sigma_{j=1..L}\ AP_j$$

**L** jumlah label; **j** indeks label. Ilustrasi dua label: AP label A = 34/45 ≈ 0,7556 dari halaman 17, dan AP label B diasumsikan 0,40. Jumlah = 1,1556; bagi dua → **macro AP ≈ 0,5778**. Asumsi label B hanya untuk latihan rata-rata.

## Macro F1 bukan F1 dari rata-rata P dan R

Ilustrasi: label A dari halaman 16 mempunyai P = 1/2, R = 2/3, F1 = 4/7. Label B mempunyai TP=1, FP=0, FN=2: P=1, R=1/3, F1=1/2.

**1.** Macro F1 = (4/7 + 1/2) / 2 = 15/28 ≈ **0,5357**.
**2.** Rata-rata P = (1/2 + 1)/2 = 0,75; rata-rata R = (2/3 + 1/3)/2 = 0,50.
**3.** F1 dari kedua rata-rata itu = 2 × 0,75 × 0,50 / 1,25 = **0,60**. Ini bukan macro F1 yang dipakai proyek.

## AUROC: pasangan positif mengalahkan negatif

Laporan menjelaskan AUROC sebagai luas kurva ROC; kode memakai roc_auc_score. Berikut cara manual ekuivalen untuk memahami ranking, bukan rumus baru yang ditambahkan ke laporan.

| Skor positif | Negatif yang skornya lebih rendah | Menang |
|---|---|---|
| 0,90 | 0,80; 0,60; 0,10 | 3 |
| 0,70 | 0,60; 0,10 | 2 |
| 0,40 | 0,10 | 1 |

Ada 3 positif × 3 negatif = **9 pasangan**. Positif menang 3 + 2 + 1 = 6 pasangan. AUROC = 6/9 ≈ **0,6667**. Jika skornya seri, pasangan dihitung setengah menang. Perhitungan membutuhkan kedua kelas.

AP dan AUROC melihat ranking dari sudut berbeda. Mengubah threshold keputusan saja tidak mengubah keduanya. Untuk label tidak seimbang, AP membantu fokus pada ketepatan dan penemuan anotasi positif; itulah kriteria seleksi proyek.

## Buka notebook setelah konsepnya nyambung

**07_Evaluasi_dan_Pemilihan.ipynb**
metrics.binary_metrics → metrics.summarize

Mulai dari bagian Persiapan saat membuka notebook mandiri. Cari judul di atas dengan Ctrl+F; baca penjelasan, source, lalu output tepat di bawahnya.

Rujukan: Bab2: eq:macro_ap, Macro F1, AUROC; 03_Kode/metrics.py; validation.prediction_diagnostics pada notebook 06.

LANGKAH 19 / PANDUAN INTI

# Threshold OOF: tambahan, bukan hasil utama

Threshold utama penelitian dan aplikasi adalah 0,5. Threshold per label yang dipilih dari OOF dilaporkan sebagai analisis tambahan.

## Aturan implementasinya

Ambil rata-rata skor OOF lima seed pada train. Untuk tiap label, coba threshold **0,05 sampai 0,95** dengan langkah **0,05**. Hitung F1 dari keputusan skor ≥ threshold. Pilih F1 terbesar. Jika seri, pilih yang paling dekat 0,5; jika masih seri, pilih threshold lebih besar.

## Ilustrasi dengan data halaman 16

| Threshold | TP | FP | FN | Hitungan F1 |
|---|---|---|---|---|
| 0,90 | 1 | 0 | 2 | 2/(2+0+2) = 0,50 |
| 0,70 | 2 | 1 | 1 | 4/(4+1+1) = 0,6667 |
| 0,50 | 2 | 2 | 1 | 4/(4+2+1) = 0,5714 |
| 0,40 | 3 | 2 | 0 | 6/(6+2+0) = 0,75 |

Tabel menampilkan empat kandidat threshold dari grid, bukan seluruh grid. Pada data latihan ini, threshold 0,15-0,40 sama-sama mengambil lima baris teratas dan menghasilkan F1 = 0,75. Aturan seri memilih **0,40** karena paling dekat 0,50. Dalam pemilihan sungguhan, skor yang dipakai wajib OOF train, bukan skor test.

## Hasil asli LightGBM D pada test

| Metrik | Threshold 0,5 | Threshold OOF |
|---|---|---|
| Macro F1 | 0,293156 | 0,330419 |
| Macro precision | 0,213862 | 0,303265 |
| Macro recall | 0,515089 | 0,411890 |

F1 dan precision naik, tetapi recall turun. Ini tradeoff: prediksi lebih selektif, sebagian positif tercatat lebih banyak terlewat. AP test tetap **0,310531** karena skor dan ranking tidak berubah.

OOF masih berasal dari proses pengembangan yang terkait seleksi parameter; ini tidak bebas bias seleksi. Penyesuaian threshold tidak menjamin F1 test naik pada semua kandidat.

## Buka notebook setelah konsepnya nyambung

**06_Optuna_CV_dan_OOF.ipynb**

validation.f1_from_metrics → validation.select_validation_thresholds → Hitung ulang ambang dari OOF tersimpan

Mulai dari bagian Persiapan saat membuka notebook mandiri. Cari judul di atas dengan Ctrl+F; baca penjelasan, source, lalu output tepat di bawahnya.

Rujukan: Bab3: Evaluasi; lampiran rincian_reproduksi dan evaluasi_tambahan; 03_Kode/validation.py.

LANGKAH 20 / PANDUAN INTI

# Hasil akhir: mengapa LightGBM D?

Semua angka pada halaman ini adalah hasil asli eksperimen utama, dibulatkan enam desimal. Pilihan berasal dari validasi, bukan dari pemilihan skor test tertinggi.

| Kandidat | Mean AP CV | AP test | F1 test (0,5) |
|---|---|---|---|
| XGBoost A | 0,249589 | 0,249043 | 0,274899 |
| XGBoost B | 0,277412 | 0,288125 | 0,311835 |
| XGBoost C | 0,267049 | 0,273029 | 0,270369 |
| XGBoost D | 0,296959 | 0,308827 | 0,305902 |
| LightGBM A | 0,251681 | 0,252837 | 0,277184 |
| LightGBM B | 0,283211 | 0,296380 | 0,320721 |
| LightGBM C | 0,269114 | 0,276461 | 0,252220 |
| **LightGBM D** | **0,299731** | **0,310531** | **0,293156** |

**1. Kriteria:** rata-rata macro AP validasi lima seed tertinggi.
**2. Pemenang:** LightGBM D = 0,299731; XGBoost D = 0,296959.
**3. Selisih:** 0,299731 - 0,296959 ≈ **0,002772** berdasarkan angka presisi penuh. Keunggulan tipis dan deskriptif; tidak ada bukti signifikansi statistik atau keunggulan universal.

## Apa yang didukung hasilnya?

Tambahan deskriptor meningkatkan AP pada B-A dan D-C untuk kedua algoritma. Tuning meningkatkan AP pada C-A dan D-B. Namun macro F1 pada threshold 0,5 justru lebih rendah setelah tuning; LightGBM B mencapai F1 0,320721, lebih tinggi daripada D.

**Kalau dosen bertanya "bagus atau belum?"**
"LightGBM D paling baik menurut kriteria AP validasi di eksperimen ini. AP test 0,310531 bukan akurasi 31%. Performa bergantung label, anotasi belum lengkap, dan generalisasi eksternal belum dibuktikan."

**Jebakan accuracy:** label accuracy LightGBM D = 0,923660. Prediksi semua nol mencapai 0,960970, tetapi recall dan F1 nol. Accuracy tinggi sendirian belum membuktikan model berguna untuk menemukan aroma.

## Buka notebook setelah konsepnya nyambung

**07_Evaluasi_dan_Pemilihan.ipynb**
Baca delapan kandidat dan hasil utama → Reproduksi pilihan dari CV tersimpan → Baca delta dan cek kesamaan cakupan

Mulai dari bagian Persiapan saat membuka notebook mandiri. Cari judul di atas dengan Ctrl+F; baca penjelasan, source, lalu output tepat di bawahnya.

Rujukan: Bab4: Perbandingan Delapan Kandidat; artefak asli comparison_all.csv dan selection_frozen.json, juga disalin ke 04_Hasil.

LANGKAH 21 / PANDUAN INTI

# Dari model tersimpan ke prediksi molekul

Prediksi baru memakai model final yang sudah dilatih. Tidak ada training ulang hanya karena kamu memasukkan satu SMILES.

| Tahap | Input → proses → output |
|---|---|
| 1. Masukan | SMILES satu molekul → periksa struktur → objek molekul valid. |
| 2. Fitur | Struktur → Morgan 2.048 + delapan deskriptor dalam urutan tetap → satu baris berisi 2.056 angka. |
| 3. Inferensi | Fitur → 109 classifier LightGBM D tersimpan → 109 skor. |
| 4. Keputusan | Skor → bandingkan dengan 0,5 → daftar label yang lolos. |

Notebook 08 memperlihatkan inferensi Python dari model tersimpan. Pada prototipe Essenza, layanan fitur **Python/RDKit di komputer lokal** menghitung fitur, lalu **109 model ONNX di Android** melakukan inferensi. Proses ini memerlukan kesesuaian urutan fitur, label, dan threshold.

Integrasi tersedia dan sudah diuji terbatas; jangan mengikuti status lama yang masih menyebut ONNX ditunda. Ini belum membuktikan manfaat pengguna, validitas sensori, atau kesiapan produksi. SMILES valid juga tidak otomatis berarti berada dalam domain bahan pewangi yang dipelajari.

## Buka notebook setelah konsepnya nyambung

**08_Prediksi_Molekul.ipynb**
Temukan hasil utama dan kontrak model → inference.predict → Jalankan prediksi nyata → Lihat keputusan positif

Mulai dari bagian Persiapan saat membuka notebook mandiri. Cari judul di atas dengan Ctrl+F; baca penjelasan, source, lalu output tepat di bawahnya.

Rujukan: Bab3: Implementasi Essenza; Bab4: pengujian aplikasi; 03_Kode/inference.py. Notebook menjalankan model Python; pengujian Android adalah jalur terpisah.

## Pegangan sumber ketika ada tulisan yang berbeda

**Laporan utama:** SKRIPSI.tex → src/2.Isi/Bab1.tex sampai Bab5.tex, serta lampiran yang disertakan. Lokasi:

C: / Users / ACER / Documents / Marvel / Skripsi / Laporan Skripsi / 2521_skripsi_Marvel_Kevin_Nathanael

**Kode:** KODE_ML/03_Kode; konfigurasi: config/experiment.json. **Hasil:** results.py menunjuk arsip utama yang dikunci; salinan belajar di 04_Hasil. **05_Referensi/Laporan** adalah snapshot lama dan dapat berbeda dari laporan aktif. PDF ini memakai laporan utama, bukan snapshot tersebut.

Rumus bernomor yang dicakup: eq:label_threshold; eq:bobot_kelas_seimbang; eq:average_precision; eq:macro_ap; eq:precision_recall; eq:accuracy_specificity; eq:optuna_objective. F1, rata-rata seed, dan SD mengikuti uraian laporan serta operasi kode. Tidak menambah rumus loss/gradient sebagai rumus laporan.

LANGKAH 22 / PANDUAN INTI

# Latihan sidang: ceritakan tanpa membaca

Jawab dengan pola: keputusan yang dipakai → alasannya → batas klaimnya. Tidak perlu menghafal seluruh baris source.

| Pertanyaan dosen | Contoh jawaban singkat |
|---|---|
| Mengapa multi-label? | Satu molekul bisa memiliki beberapa label aroma. Binary Relevance melatih satu classifier untuk tiap label. |
| Mengapa Morgan + 8? | Morgan menangkap pola lokal struktur; delapan deskriptor melengkapi sifat molekul. Manfaat paketnya diuji lewat A-D, bukan diasumsikan optimal. |
| Mengapa tidak split acak per baris? | Kelompok mencegah identitas yang ditentukan protokol tersebar ke fitting dan evaluasi. Ini belum menjamin pemisahan semua kemiripan atau scaffold. |
| Mengapa AP? | Label tidak seimbang. AP menilai ranking dengan precision dan recall; macro memberi bobot sama ke setiap label. |
| Mengapa bukan model F1 tertinggi? | Kriteria seleksi ditetapkan memakai AP validasi. F1 pada threshold 0,5 adalah ukuran pendukung dan menunjukkan tradeoff. |
| Apakah 0 berarti aromanya tidak ada? | Nol berarti tidak tercatat pada target, bukan negatif sensori terverifikasi. |
| Apakah test sepenuhnya baru? | Pada run utama, pilihan dikunci sebelum evaluasi test. Namun test pernah diakses dalam pengembangan sebelumnya, sehingga hasilnya eksploratori. |
| Apa keterbatasan terbesarnya? | Anotasi tidak lengkap, imbalance, fitur identik dengan target berbeda, CV bukan nested, serta belum ada validasi eksternal/sensori. |

## Checklist sebelum kamu bilang “sudah paham”

□ Bisa menjelaskan gap ilmiah, alasan memilih dua model, dan batas tanpa RF.
□ Bisa menggambar alur SMILES → fitur → 109 classifier → skor → label.
□ Bisa menghitung bobot, threshold, TP/FP/FN/TN, P/R/F1, AP, macro AP, mean CV, dan SD dari contoh panduan.
□ Bisa menunjuk notebook dan fungsi yang menjalankan tiap tahap.
□ Bisa membedakan ilustrasi, hasil utama, serta analisis tambahan.
□ Bisa menjelaskan alasan LightGBM D dipilih dan batas hasilnya.

**Latihan terakhir, sekitar satu menit**
Ceritakan gap ilmiah, alasan memilih dua model tanpa RF, alur penelitian, lalu satu hasil dan dua keterbatasannya. Jika masih tersendat, ulangi halaman yang terkait, bukan seluruh PDF sekaligus.

Peta bagian notebook tersimpan juga di 01_Materi/Peta_Notebook.md. Untuk pertanyaan detail implementasi, buka notebook yang dirujuk pada halaman terkait. Materi lama disimpan sebagai referensi historis di 05_Referensi.