LANGKAH 01 / INTI + RUJUKAN

Satu jalur belajar, dari awal sampai sidang

Ikuti bagian inti terlebih dahulu, lalu buka notebook yang diarahkan. Bagian bertanda Pendalaman opsional boleh dibaca setelah alur utamanya paham.

Cerita penelitianmu
Struktur **satu molekul** → fitur angka → model untuk tiap label → skor → beberapa label aroma. Model belajar mencocokkan fitur dengan **anotasi yang tercatat**, bukan mencium molekul secara langsung.

Urutan baca	Halaman
Alasan ilmiah, gap, dan kontribusi penelitian	2-3
Desain kandidat dan pilihan model; RF opsional	4-6
Dataset, preprocessing, fitur, dan pembagian data	7-10
Model, bobot kelas, training, dan tuning	11-13
CV, lima seed, dan OOF	14-15
Hitungan evaluasi: confusion matrix sampai AUROC	16-18
Threshold tambahan dan hasil asli	19-20
Prediksi, sumber rujukan, dan latihan sidang	21-22

Pola belajar yang dipakai

Inti: keputusan, alasan, hasil, serta keterbatasannya. Kerjakan contoh bobot, threshold, confusion counts, P/R/F1, AP, macro AP, dan mean. **Rujukan:** cukup tahu fungsi serta lokasi detail. **Pendalaman opsional:** hitungan akar SD, enumerasi pasangan AUROC, dan jawaban lanjut tentang RF. Makna SD, AUROC, serta batas tanpa RF tetap inti.

Angka ilustrasi di kotak latihan dibuat kecil supaya bisa dihitung manual. Rumus dan aturannya mengikuti implementasi. **Hasil asli** diberi tanda dan berasal dari artefak utama yang dikunci.

Cukup tiga pintu masuk

PDF ini untuk alur dan rumus; **notebook 01-08** untuk kode lengkap; **04_Hasil/comparison_all.csv** untuk hasil delapan kandidat. 01_Materi adalah bacaan pendalaman opsional.

Notebook sudah berisi output. Kamu boleh membacanya tanpa menjalankan sel. Menjalankan notebook dapat menghitung fitur, audit, atau inferensi; gerbang eksperimen penuh pada notebook 07 tetap False. Jangan diaktifkan hanya untuk belajar.

Revisi editorial 6 November 2026 berdasarkan audit dan sumber terkini; metode serta hasil tetap. Hasil utama: arsip perfume-five-grouped-v7-m2048-d8. Nama arsip bukan nama metode.

LANGKAH 02 / INTI + RUJUKAN

Mengapa topik ini layak diteliti?

Alasan utamanya adalah masalah ilmiah yang bisa diuji: bagaimana memetakan struktur molekul menjadi beberapa label aroma, dan informasi fitur apa yang membantu prediksinya?

1. Struktur tersedia, tetapi hubungan dengan aroma tidak sederhana

Saini dan Ramanathan [1] menempatkan prediksi struktur-aroma sebagai masalah multi-label: satu molekul dapat memiliki beberapa anotasi aroma. Pola struktur dan sifat molekul menjadi masukan untuk memeringkat anotasi tersebut.

2. Ada data untuk belajar, sekaligus masalah yang perlu dikendalikan

Hamel dkk. [2] memperkenalkan Pyrfume untuk mengintegrasikan data olfaksi yang tersebar. Ketersediaan data membuka peluang pemodelan, tetapi tidak otomatis membuat anotasi seragam atau evaluasi dapat dibandingkan.

Masalah pada penelitianmu	Mengapa penting secara ilmiah
Istilah dan anotasi tidak seragam	Penyelarasan menentukan target yang dipelajari. Target nol belum membuktikan aroma tidak ada.
Dukungan label tidak seimbang	Model perlu dinilai dari kemampuan menemukan positif; accuracy saja bisa menyesatkan.
Identitas/fitur molekul dapat berulang	Pemisahan kelompok diperlukan agar representasi identik tidak tersebar ke fitting dan evaluasi.

3. Pertanyaannya spesifik, bukan sekadar “membuat prediksi aroma”

Apakah delapan deskriptor fisikokimia melengkapi Morgan fingerprint, dan bagaimana respons dua algoritma boosting terhadap tambahan fitur serta tuning? Morgan merangkum pola lokal, sedangkan deskriptor memberi ringkasan sifat molekul. Manfaat penggabungannya harus diuji; lebih banyak fitur belum tentu lebih baik.

Gap relatif terhadap acuan dan kontribusi perbandingan internal dirangkum di halaman 3; desain A-D dijelaskan di halaman 4.

[1] Saini & Ramanathan (2022), *Predicting odor from molecular structure: a multi-label classification approach*. doi:10.1038/s41598-022-18086-y.
[2] Hamel dkk. (2024), *Pyrfume: A window to the world's olfactory data*. doi:10.1038/s41597-024-04051-z. Masalah data pada tabel dirujuk ke audit proyek serta Bab1/Bab3 laporan utama.

LANGKAH 03 / INTI + RUJUKAN

Gap yang ditindaklanjuti dan kontribusi skripsimu

Gap berarti pertanyaan yang belum dijawab oleh eksperimen acuan yang kamu telaah. Ini tidak otomatis berarti belum pernah ada satu pun penelitian serupa di dunia.

Dari acuan menjadi pertanyaan penelitian sendiri

Suh dkk. [3] mengevaluasi Morgan, delapan deskriptor, dan gugus fungsi sebagai representasi terpisah. Eksperimen tersebut belum langsung menjawab manfaat **menambahkan paket delapan deskriptor ke Morgan** pada kohor dan protokol penelitianmu.

Pertanyaan tersebut diuji melalui delapan kandidat pada dataset dan pembagian kelompok yang sama. Desain A-D serta arti selisih antarkondisi cukup dipelajari sekali pada halaman 4. Lima pengulangan grouped CV memeriksa variasi pembagian train; prosedurnya bukan nested CV.

Perbandingan dalam data yang sama diperlukan supaya selisih skor tidak sekadar berasal dari perbedaan kohor, kosakata label, atau split. Kontribusinya adalah **bukti empiris internal tentang fitur dan tuning**, bukan penciptaan algoritma baru atau pembuktian paling unggul atas semua model.

Contoh jawaban sidang: “Mengapa memilih topik ini?”

Satu jawaban yang menghubungkan masalah dan kontribusi
“Saya menguji tambahan delapan deskriptor pada Morgan serta tuning pada dua algoritma boosting. Kontribusinya berupa perbandingan internal pada data yang sama dan integrasi model terpilih ke Essenza. Kesimpulan dibatasi kualitas anotasi serta protokol evaluasinya.”

Lalu, kegiatan meracik parfum ditempatkan di mana?

Itu **motivasi penerapan dan pemicu ide pribadi**: informasi awal aroma per senyawa berstruktur diketahui dapat menjadi bahan pertimbangan sebelum uji racik. Video TikTok yang kamu ceritakan memberi konteks tersebut; manfaat bagi peracik belum diuji, dan aroma akhir campuran bukan keluaran model.

[3] Suh, Hong & Park (2025), *A comparative study of machine learning models on molecular fingerprints for odor decoding*. doi:10.1038/s42004-025-01651-7. Gap/kontribusi mengikuti Bab1, Bab2, dan Bab5 laporan utama. Narasi ini memperjelas posisi studi terhadap acuan yang ditelaah, bukan tinjauan sistematis seluruh literatur.

LANGKAH 04 / INTI + RUJUKAN

Desain delapan kandidat: fitur dan tuning

Dua algoritma masing-masing memiliki empat kondisi A-D. Gunakan matriks ini untuk menjelaskan perbandingan yang benar-benar dilakukan.

Penelitian terdahulu memberi pijakan

Acuan di Bab II	Yang kamu ambil dari konteksnya
Keller dkk. (2017)	Struktur kimia dapat dipakai untuk memodelkan atribut persepsi aroma.
Saini & Ramanathan (2022)	Satu molekul bisa punya banyak label; Binary Relevance adalah salah satu pendekatannya.
Tyagi dkk. (2024)	Memberi konteks pemanfaatan informasi fisikokimia. Data dan metriknya berbeda.
Suh dkk. (2025)	Membandingkan representasi serta algoritma. Delapan deskriptor, Morgan, dan gugus fungsi diuji sebagai representasi terpisah.

Gabungan Morgan + 8 adalah eksperimen proyekmu; jangan mengklaim konfigurasi gabungan ini menyalin eksperimen representasi terpisah pada Suh.

Empat kondisi untuk setiap algoritma

Kondisi	Masukan	Pengaturan
A	Morgan: 2.048 fitur	Baseline 100 pohon
B	Morgan + 8: 2.056 fitur	Baseline 100 pohon
C	Morgan: 2.048 fitur	Hasil tuning Optuna
D	Morgan + 8: 2.056 fitur	Hasil tuning Optuna

B-A menilai tambahan deskriptor pada baseline tetap. **C-A** dan **D-B** menilai hasil tuning. **D-C** juga melibatkan parameter terbaik yang mungkin berbeda, jadi bukan efek fitur murni.

Kontribusi dan jawaban singkatnya dirangkum di halaman 3. Tabel ini menjadi pegangan saat membaca hasil delapan kandidat di halaman 20.

Rujukan: laporan utama Bab2, “Penelitian Terdahulu”; Bab3, “Rancangan Penelitian”. Baca 05_Referensi jika ingin mendalami paper. Skor antarpenelitian tidak dibandingkan langsung karena data, label, split, dan metrik berbeda.

LANGKAH 05 / INTI + RUJUKAN

Mengapa XGBoost dan LightGBM?

Dasarnya terdiri dari dukungan empiris di penelitian aroma, kesesuaian dengan fitur molekul, dan perbedaan implementasi boosting yang layak dibandingkan.

1. Ada dukungan domain yang langsung relevan

Pada **Morgan/ST**, Table 2 Suh [3] melaporkan hasil test berikut. Ini angka penelitian Suh, bukan hasil skripsimu dan bukan ukuran yang langsung dapat dibandingkan dengan skor skripsi.

Model pada Morgan	AUROC Suh	AUPRC Suh
XGBoost	0,828	0,237
LightGBM	0,810	0,228
Random Forest	0,784	0,216

XGBoost dan LightGBM berada di atas RF menurut dua metrik ranking tersebut. Ini mendukung pemilihan kandidat untuk ditelaah lebih lanjut. Namun RF mempunyai precision lebih tinggi daripada LightGBM pada tabel yang sama (0,279 vs 0,215); jangan menyebut RF kalah pada semua metrik.

2. Cocok untuk fitur, tetapi cara tumbuhnya berbeda

Vektor Morgan dan deskriptor adalah fitur numerik. Boosting pohon dapat membentuk aturan nonlinier serta interaksi fitur dan dipakai sebagai classifier biner per label. Perbedaan berikut relevan pada konfigurasi proyek [4-6].

Aspek	XGBoost proyek	LightGBM proyek
Pertumbuhan pohon	Depthwise: prioritas simpul lebih dekat akar; default versi 2.1.4.	Leaf-wise: prioritas daun dengan perbaikan loss terbesar.
Kendali kompleksitas	Antara lain max_depth, min_child_weight, gamma, L1/L2.	Antara lain num_leaves, max_depth, min_child_samples, L1/L2.
Pencarian split	Histogram: tree_method=hist.	Histogram pada GBDT.

Kendali kompleksitas membatasi kerumitan model; **loss** adalah nilai kesalahan yang dioptimalkan. Karena cara tumbuh dan kendalinya berbeda, respons kedua model terhadap fitur dan tuning perlu diuji. RF juga sesuai untuk fitur ini, sehingga kesesuaian masukan bukan alasan menolaknya.

[4] Chen & Guestrin (2016), *XGBoost: A Scalable Tree Boosting System*.
[5] Parameter resmi XGBoost v2.1.4, grow_policy/tree_method.
[6] Dokumentasi resmi LightGBM 4.6, Features, histogram dan leaf-wise. Cocok dengan training.py/config proyek. GOSS tidak dinyatakan dipakai; tidak ada klaim kecepatan universal.

LANGKAH 06 / PENDALAMAN OPSIONAL

Catatan opsional: mengapa tanpa RF?

Inti yang tetap perlu dipahami: RF tidak diuji pada dataset proyek. Karena itu, hasil tidak membuktikan boosting lebih baik daripada RF atau semua keluarga model.

Jawaban singkat untuk sidang
"Saya memfokuskan eksperimen pada dua implementasi gradient boosting untuk membandingkan fitur dan tuning. RF tetap pembanding yang valid. Karena tidak diuji pada data sendiri, belum diketahui apakah RF dapat mengungguli model terpilih."

Pendalaman opsional: posisi keluarga metode

Keluarga metode	Perbedaan umum
Random Forest [7]	Menggabungkan pohon dengan randomisasi data/fitur; keluarga bagging/randomized trees.
XGBoost dan LightGBM	Membangun ensemble bertahap untuk memperbaiki objective model gabungan; keluarga gradient boosting.

Baseline A/B adalah pembanding konfigurasi di dalam XGBoost/LightGBM, bukan pengganti baseline RF. Penambahan RF merupakan perluasan pembandingan yang bernilai, tetapi berada di luar delapan kandidat saat ini.

Konteks alasan: Bab1 mengaitkan pemilihan model dengan sifat boosting, pertumbuhan pohon, dan kendali kompleksitas. Hasil Suh pada halaman 5 merupakan dukungan literatur, bukan bukti alasan historis awal atau bukti RF gagal pada data proyek.

[7] Breiman (2001), *Random Forests*, bagian 1 dan 3.1. Paper primer penulis. Fokus eksperimen: Bab1/Bab3 laporan utama; experiment.py: ALGORITHMS dan CANDIDATES.

LANGKAH 07 / INTI + RUJUKAN

Dataset itu isinya apa?

Satu baris akhir mewakili satu molekul. Kolom masukan menggambarkan strukturnya; kolom target menunjukkan label aroma yang tercatat.

Lima sumber melalui Pyrfume

Sumber	Bentuk catatan aroma
GoodScents	Teks deskriptor
IFRA 2019	Tiga kolom deskriptor; sumber kamus target
Leffingwell	Indikator biner deskriptor
Arctander 1960	Teks label aroma
Sigma-Aldrich 2014	Indikator biner aroma

Catatan aroma dan struktur bisa berada di tabel berbeda. **Stimulus** mengidentifikasi stimulus pada sumber; **CID** adalah pengenal senyawa PubChem; **CAS** adalah pengenal registrasi senyawa. Kode menyambungkan identitas yang tersedia, bukan menyamakan posisi baris.

Ilustrasi join, bukan baris dataset asli
Tabel anotasi: Stimulus S1 → floral. Tabel penghubung: S1 → CID 123. Tabel molekul: CID 123 → SMILES. Setelah join, anotasi floral terhubung ke struktur itu. Angka 123 hanya pengenal ilustrasi, bukan identitas molekul yang diverifikasi.

Bentuk akhir hasil kurasi - angka asli

Bagian	Jumlah molekul	Target
Train	5.353	109 kolom label
Test	1.333	109 kolom label
Total	6.686	Satu baris bisa punya banyak label

X adalah matriks fitur masukan; **Y** adalah matriks target. Untuk model D, X train berukuran 5.353 × 2.056 dan Y train 5.353 × 109. Tanda × berarti jumlah baris dikali jumlah kolom, bukan jumlah kelas baru.

Buka notebook setelah konsepnya nyambung

01_Sumber_Data.ipynb
Konfigurasi sumber → Baca snapshot dan ukur tabel → Ikuti contoh join GoodScents

Cari judul dengan Ctrl+F. Baca konsep, fungsi inti, dan output; helper, log, penyimpanan, serta audit lengkap cukup dirujuk saat perlu.

Rujukan: Bab3: Akuisisi dan Kurasi Data; 03_Kode/preprocessing.py dan source_identity.py. Data belajar: 02_Data/README.md.

LANGKAH 08 / INTI + RUJUKAN

Preprocessing: merapikan tanpa menebak

Tujuannya memastikan struktur valid, identitas cocok, dan istilah aroma masuk ke kosakata yang sama sebelum model belajar.

Urutan	Yang dilakukan dan alasannya
1. Cocokkan identitas	Hubungkan anotasi dan struktur lewat pengenal yang dapat diverifikasi.
2. Periksa struktur	Tolak struktur kosong, tidak valid, atau multifragmen. Tidak mengisi SMILES kosong dengan imputasi dan tidak otomatis memilih fragmen terbesar.
3. Selaraskan istilah	Normalisasi huruf/tanda baca/spasi; cocokkan langsung atau lewat alias eksplisit. Tolak baris tanpa label terpetakan; tidak memakai fuzzy matching.
4. Kanonisasi dan gabung	Samakan penulisan SMILES; gabungkan hanya SMILES kanonik identik. Satukan himpunan label dan simpan asal anotasi.
5. Bentuk target	Setelah pembagian awal, pilih label dengan ≥30 positif dan ≥2 negatif pada train. Hasilnya 109 label.

Kanonisasi bukan berarti semua stereoisomer, tautomer, dan bentuk protonasi disatukan. Struktur stereokimia masih dicatat; fitur Morgan yang dipakai justru tidak memasukkan chirality.

Contoh aturan label yang benar-benar ada

jasmine → **jasmin** adalah salah satu alias. **tropical** → **tropical fruit** juga ada, tetapi perubahan makna ini perlu tinjauan ahli; jangan menyebut semua alias pasti benar secara sensori.

Tiga angka yang beda fungsi
184 istilah kamus IFRA; **31** aturan alias; **109** target model setelah seleksi dukungan train. Ini bukan tiga versi jumlah kelas yang bisa dipertukarkan.

Hasil audit asli: 6.494 kemunculan istilah dari 498 bentuk tidak terpetakan; 3.898 baris sumber yang diterima tetap kehilangan sebagian token. Setelah seleksi target, 11 baris train dan 4 test seluruhnya nol, dan tetap dipertahankan.

Target 1 = label tercatat; **target 0** = tidak tercatat. Nol belum membuktikan molekul tidak beraroma tersebut.

Buka notebook setelah konsepnya nyambung

02_Preprocessing_dan_Audit_Label.ipynb
normalize → taxonomy_from_ifra → tokens_for → map_labels → merge_sources → Buktikan asal angka 109 → Rekonsiliasi jumlah baris dan token

Cari judul dengan Ctrl+F. Baca konsep, fungsi inti, dan output; helper, log, penyimpanan, serta audit lengkap cukup dirujuk saat perlu.

Rujukan: Bab3: Harmonisasi dan Encoding Label; 03_Kode/preprocessing.py; 06_Audit_Label/summary.json.

LANGKAH 09 / INTI + RUJUKAN

Fingerprint dan deskriptor: struktur menjadi angka

Model tidak langsung membaca huruf SMILES. RDKit lebih dulu mengubah struktur molekul menjadi fitur numerik.

Morgan: pola di sekitar atom

Radius 2 berarti menjangkau lingkungan lokal sampai dua ikatan dari atom pusat. Lingkungan dipetakan lewat hashing ke **2.048 posisi bit**. Nilai 1 berarti ada pola yang terpetakan ke posisi itu; 0 berarti posisi itu tidak terisi. Satu bit bisa menerima beberapa pola berbeda: ini disebut collision.

Ilustrasi sederhana, bukan hasil hashing RDKit
Pola A dan pola B sama-sama masuk posisi ke-3; posisi itu tetap bernilai 1. Vektor kecil [0, 0, 1, 0] hanya membantu memahami collision. Model asli memakai 2.048 bit, bukan 4 bit.

includeChirality=False berarti ciri kiral tidak disertakan pada fingerprint. Molekul yang berbeda stereokimia dapat memiliki fitur sama. Audit menemukan 1.474 molekul berada dalam kelompok fitur identik tetapi targetnya berbeda; ini batas representasi/anotasi, bukan otomatis kesalahan semua molekul tersebut.

Delapan angka pelengkap, dalam urutan aktual

Deskriptor	Yang diringkas
MolWt / MolLogP	Massa molekul relatif / estimasi lipofilisitas
NumHDonors / NumHAcceptors	Jumlah donor / akseptor ikatan hidrogen
TPSA	Luas permukaan polar topologis
NumRotatableBonds	Jumlah ikatan yang dapat berotasi menurut RDKit
HeavyAtomCount / RingCount	Jumlah atom selain H / jumlah cincin menurut RDKit

A/C memakai 2.048 fitur; B/D memakai 2.048 + 8 = **2.056 fitur**. Masukan akhirnya float32; deskriptor tidak distandardisasi atau dinormalisasi skalanya pada pipeline ini. Nilai tidak finite menghentikan proses.

Bit fitur 0/1 berbeda dengan target aroma 0/1. Bit adalah masukan pola struktur; target adalah jawaban anotasi yang ingin dipelajari.

Buka notebook setelah konsepnya nyambung

03_Dataset_dan_Fitur.ipynb
calculate_morgan → calculate → features → Lihat satu molekul yang memang ada dalam data

Cari judul dengan Ctrl+F. Baca konsep, fungsi inti, dan output; helper, log, penyimpanan, serta audit lengkap cukup dirujuk saat perlu.

Rujukan: Bab2: Representasi Molekul; Bab3: Ekstraksi Fitur; 03_Kode/features.py. Temuan fitur identik: 04_Hasil/audit_27_oktober/README.md.

LANGKAH 10 / INTI + RUJUKAN

Train, test, dan fold: siapa dipakai untuk apa?

Pisahkan tiga peran: data untuk belajar model, data validasi untuk menilai pilihan, dan data test untuk evaluasi akhir setelah keputusan dikunci.

Bagian	Peran dalam penelitian
Train: 5.353 molekul	Sumber fitting dan validasi silang untuk tuning serta seleksi kandidat.
Validation fold	Bagian dari train yang sementara ditahan saat satu model fold belajar.
Test: 1.333 molekul	Dievaluasi setelah resep, pilihan kandidat, dan threshold dibekukan pada run utama.

Kenapa menggunakan kelompok?

Struktur identik tanpa stereo atau Morgan **1.024 bit identik** dihubungkan secara transitif menjadi kelompok historis. Kalau A terhubung ke B dan B ke C, ketiganya satu kelompok. Anggota satu kelompok harus berada pada sisi pembagian yang sama.

Fingerprint 1.024 di sini dipakai untuk **asal kelompok**, bukan fitur training utama. Model utama tetap Morgan 2.048. Kelompok beku dipakai kembali supaya delapan kandidat dibandingkan pada pemisahan yang sama.

Ilustrasi kelompok
Misal A dan B satu grup. Jika A masuk train, B tidak boleh masuk test. Saat train dibagi menjadi fold, keduanya juga tidak boleh terpisah antara fitting dan validation pada fold yang sama.

Lima fold berarti lima giliran

Bayangkan bagian train dikelompokkan menjadi lima bagian. Giliran 1: empat bagian untuk fitting, satu bagian untuk validasi. Giliran berikutnya: bagian yang ditahan berganti. Model tiap giliran dilatih dari awal, bukan melanjutkan model sebelumnya.

Implementasi memakai **GroupShuffleSplit** untuk train-test dan **StratifiedGroupKFold per label** untuk fold. Jadi jangan menganggap satu tabel fold berlaku bersama untuk seluruh label. Fold label-seed yang sama digunakan seluruh kandidat.

Aturan ini mencegah irisan kelompok yang didefinisikan protokol, bukan seluruh kemiripan molekul atau scaffold. Test pernah dilihat dalam pengembangan sebelumnya; hasil tetap eksploratori.

Buka notebook setelah konsepnya nyambung

04_Grup_Split_dan_Fold.ipynb
Bedakan pembentukan historis dengan pemakaian saat ini → structure_feature_groups → outer_split → inner_folds → Contoh pembagian satu label

Cari judul dengan Ctrl+F. Baca konsep, fungsi inti, dan output; helper, log, penyimpanan, serta audit lengkap cukup dirujuk saat perlu.

Rujukan: Bab3: Pembagian Data dan Validasi; asal_kohor.py; 03_Kode/splits.py.

LANGKAH 11 / INTI + RUJUKAN

109 classifier, bukan 109 pohon

Binary Relevance memisahkan tugas multi-label menjadi 109 masalah biner. Setiap classifier mempelajari satu kolom target dan berisi banyak pohon.

Model belajar apa?

Classifier floral menerima fitur molekul dan target floral 0/1. Classifier woody menerima fitur yang sama, tetapi target woody 0/1. Hubungan antarlabel tidak dipelajari secara eksplisit oleh Binary Relevance.

Boosting menambahkan pohon bertahap untuk memperbaiki prediksi ensemble. Pohon menyumbang nilai numerik ke model gabungan; keluaran bukan voting mayoritas label dari seluruh pohon. Proses optimasinya dikerjakan pustaka XGBoost/LightGBM.

Algoritma	Perbedaan yang perlu kamu pegang
XGBoost	Boosting pohon dengan pengendalian kedalaman, regularisasi, dan aturan split; proyek menggunakan tree_method=hist.
LightGBM	Boosting dengan pertumbuhan leaf-wise: memilih daun dengan perbaikan terbaik. num_leaves dan batas data pada daun mengendalikan kompleksitas.

Rumus keputusan label - Bab II

$$\hat{y}_{ij} = I(p_{ij} \geq t_j)$$

i: molekul; **j**: label; $\mathbf{p_{ij}}$: skor positif; $\mathbf{t_j}$: threshold; $\hat{\mathbf{y}}_{\mathbf{ij}}$: keputusan prediksi. **I(kondisi)** bernilai 1 jika kondisi benar, selain itu 0. Tanda ≥ berarti lebih besar atau sama dengan.

Ilustrasi satu molekul	Skor	t = 0,50	Keputusan
floral	0,72	0,72 ≥ 0,50	1
woody	0,50	0,50 ≥ 0,50	1
sweet	0,20	0,20 < 0,50	0

Jumlah skor tidak harus 1 karena ini banyak label biner. Skor 0,72 bukan akurasi 72%, intensitas 72%, atau peluang manusia yang sudah terkalibrasi.

Buka notebook setelah konsepnya nyambung

05_Model_dan_Bobot.ipynb

training.make_model → Periksa delapan recipe aktual → Periksa model final yang sudah ada

Cari judul dengan Ctrl+F. Baca konsep, fungsi inti, dan output; helper, log, penyimpanan, serta audit lengkap cukup dirujuk saat perlu.

Rujukan: Bab2: eq:label_threshold; 03_Kode/training.py. Pengambilan skor: 03_Kode/inference.py.

LANGKAH 12 / INTI + RUJUKAN

Bobot kelas: positif yang langka diperhatikan

Kalau label jarang tercatat, model bisa lebih mudah mengejar keputusan negatif. Pembobotan memberi pengaruh lebih besar pada sampel dari kelas yang lebih sedikit.

Rumus yang benar-benar dipakai - Bab II

$$w_c = N / (2 \times N_c)$$

c adalah kelas 0 atau 1; **N** jumlah sampel pada bagian fitting; $\mathbf{N_c}$ jumlah sampel kelas c pada bagian itu; $\mathbf{w_c}$ bobot yang diberikan kepada setiap sampel kelas c. Angka 2 berasal dari dua kelas biner.

Ilustrasi satu label dalam satu training fold
Ada 10 molekul: 2 positif dan 8 negatif. Ini angka latihan, bukan jumlah kelas dari eksperimen asli.

Langkah	Hitungan
1. Bobot positif	$w_1 = 10 / (2 \times 2) = 2{,}5$
2. Bobot negatif	$w_0 = 10 / (2 \times 8) = 0{,}625$
3. Total bobot positif	2 sampel × 2,5 = 5
4. Total bobot negatif	8 sampel × 0,625 = 5

Total pengaruh bobot tiap kelas menjadi seimbang. **Jumlah baris tetap 10**; tidak ada penggandaan sampel dari rumus ini. Bobot masuk ke fit melalui sample_weight.

Bobotnya dihitung dari bagian mana?

Saat CV: hanya bagian fitting fold yang sedang dipakai. Saat final fit: seluruh 5.353 data train, per label. Tidak menggunakan label validation atau test untuk menentukan bobot.

Jawaban singkat untuk dosen
"Saya memakai aturan bobot yang sama pada kedua algoritma. Bobot dihitung ulang hanya dari data fitting agar tidak mengambil informasi kelas dari validation atau test."

Ini alasan teknis pemakaian bobot. Penelitian tidak menguji kondisi tanpa bobot, jadi hasilnya tidak membuktikan bahwa pembobotan mengungguli semua alternatif penanganan imbalance.

Buka notebook setelah konsepnya nyambung

05_Model_dan_Bobot.ipynb
training.balanced_sample_weights → Buktikan rumus bobot pada label aktual → training.fit

Cari judul dengan Ctrl+F. Baca konsep, fungsi inti, dan output; helper, log, penyimpanan, serta audit lengkap cukup dirujuk saat perlu.

Rujukan: Bab2: eq:bobot_kelas_seimbang; Bab3: Model dan Optimasi Optuna; 03_Kode/training.py.

LANGKAH 13 / INTI + RUJUKAN

Training dan tuning: dua pekerjaan berbeda

Training mempelajari isi pohon dari data. Tuning mencari pengaturan model, misalnya jumlah pohon dan learning rate, berdasarkan hasil validasi.

Tahap	Input → proses → output
Baseline A/B	Fitur + target train → fit dengan 100 pohon → resep pembanding tanpa Optuna.
Tuning C/D	Ruang parameter → trial + CV seed 42 → resep dengan AP objective terbaik dalam anggaran.
Validasi berulang	Delapan resep tetap → CV lima seed → skor seleksi dan prediksi OOF.
Kunci keputusan	Resep + validasi + threshold → selection_frozen.json → pilihan kandidat tetap.
Final fit seluruh kandidat	Seluruh 5.353 train → fit dari awal per label → 109 model final tiap kandidat.
Evaluasi test	Model final + 1.333 test → skor dan metrik → tabel hasil akhir.

Satu trial adalah satu paket parameter bersama untuk 109 classifier, dengan fitur sesuai kandidatnya. Bukan satu trial terpisah untuk tiap label. Tuning memakai empat studi: XGB C/D dan LGBM C/D, masing-masing **8 jam aktif**; total anggaran tuning 32 jam.

Tiga pengaturan yang cukup dipahami dulu

n_estimators: jumlah iterasi/pohon yang diminta. **learning_rate:** besar kontribusi pembaruan. **max_depth:** batas kedalaman pohon. LightGBM juga membatasi jumlah daun lewat num_leaves. Nilai besar tidak otomatis lebih baik karena bisa memperbesar overfitting.

Trial pertama memakai resep awal. Parameter yang belum ditetapkan disampling acak sampai ada 10 trial selesai; setelah itu TPE memakai hasil sebelumnya. Tidak ada early stopping atau pruning dalam protokol ini. Trial terbaik berarti terbaik yang sempat selesai, bukan optimum global.

Final fit menggunakan seluruh train setelah pilihan dikunci. Skor test bisa berbeda dari validasi karena data dan cara penilaiannya berbeda; kenaikan test tidak membuktikan final fit menyebabkan peningkatan.

Buka notebook setelah konsepnya nyambung

06_Optuna_CV_dan_OOF.ipynb
Baca kebijakan tuning → tuning.suggest → tuning.tune → Baca hasil empat studi sebenarnya

Cari judul dengan Ctrl+F. Baca konsep, fungsi inti, dan output; helper, log, penyimpanan, serta audit lengkap cukup dirujuk saat perlu.

Rujukan: Bab3: Model dan Optimasi Optuna; 03_Kode/tuning.py dan experiment.py. Urutan lengkap: notebook 07, experiment.run_all.

LANGKAH 14 / INTI + RUJUKAN

Cara menghitung nilai validasi satu seed

Untuk tiap label, hitung AP setiap fold lalu rata-ratakan. Setelah itu, rata-ratakan hasil seluruh label. Urutan ini mengikuti implementasi.

Rumus objective Optuna - Bab III

$$J(\theta) = (1/L) \Sigma_{j=1..L} [(1/K_j) \Sigma_{k=1..K_j} AP_{j,k}(\theta)]$$

θ (theta): satu paket hiperparameter; **J**: nilai objective yang ingin diperbesar; **L**: jumlah label; **K_j**: jumlah fold label j; **$AP_{j,k}$**: Average Precision label j pada fold k. **Σ** berarti jumlahkan. **1/L** berarti bagi hasil penjumlahan dengan L.

Pada penelitian asli, L = 109 dan semua K_j = 5. Angka AP dalam contoh berikut sengaja dibuat kecil; cara menghitung AP-nya dibahas pada halaman 17.

Ilustrasi: dua label, masing-masing lima fold

Label	F1*	F2*	F3*	F4*	F5*	Mean AP
A	0,20	0,30	0,40	0,30	0,40	0,32
B	0,10	0,20	0,20	0,20	0,30	0,20

*F1-F5 pada tabel ini berarti **Fold 1-Fold 5**, bukan metrik F1-score.

1. Label A: (0,20 + 0,30 + 0,40 + 0,30 + 0,40) / 5 = 1,60 / 5 = **0,32**.

2. Label B: (0,10 + 0,20 + 0,20 + 0,20 + 0,30) / 5 = 1,00 / 5 = **0,20**.

3. Rata-rata antarlabel: J = (0,32 + 0,20) / 2 = **0,26**. Setiap label mempunyai bobot sama, tanpa menimbang banyaknya positif label.

Yang sedang dibandingkan
Optuna membandingkan J dari paket parameter yang dicoba pada fold tuning seed 42. Setelah resep ditetapkan, seleksi delapan kandidat memakai rata-rata J dari lima seed. Keduanya jangan disebut angka yang sama.

Buka notebook setelah konsepnya nyambung

06_Optuna_CV_dan_OOF.ipynb
validation.cross_validate → validation.repeated_grouped_cv

Cari judul dengan Ctrl+F. Baca konsep, fungsi inti, dan output; helper, log, penyimpanan, serta audit lengkap cukup dirujuk saat perlu.

Rujukan: Bab3: eq:optuna_objective; 03_Kode/validation.py: cross_validate; 03_Kode/metrics.py: summarize.

LANGKAH 15 / INTI + RUJUKAN

Lima seed dan OOF: jangan dicampur angkanya

Seed pembagian yang digunakan adalah 7, 21, 42, 84, dan 100. Mereka mengubah pembagian fold; random_state estimator tetap 42.

Inti: rata-rata lima hasil CV untuk seleksi

$$J \text{ rata-rata} = (J_1 + J_2 + J_3 + J_4 + J_5) / 5$$

Subskrip 1-5 di sini menunjuk urutan pengulangan, bukan label. Ini penulisan sederhana dari operasi rata-rata lima seed yang dijelaskan Bab III dan dikerjakan validation.py.

Ilustrasi lanjutan halaman 14
Misal J lima pengulangan = 0,26; 0,28; 0,30; 0,32; 0,34. Jumlahnya 1,50. Rata-rata = 1,50 / 5 = **0,30**. Ini bukan skor validasi asli modelmu.

Inti: OOF berasal dari sampel yang ditahan dari fitting

Setiap molekul train mendapat satu skor OOF per seed dari model fold yang tidak melatih molekul itu. Lima skor OOF lalu dirata-ratakan per molekul-label. Contoh ilustrasi: (0,30 + 0,50 + 0,60 + 0,40 + 0,70) / 5 = **0,50**. Skor rata-rata ini dipakai memilih threshold tambahan.

Mean AP antarfold/seed berbeda dari AP atas skor OOF gabungan. AP melibatkan urutan skor, sehingga merata-ratakan AP dan merata-ratakan skor bukan operasi yang sama.

Makna SD tetap inti: variasi hasil antarpembagian, bukan interval kepercayaan dari lima dataset independen. Lima seed × lima fold = **25 fitting-validasi per label per kandidat**; Optuna dan final fit terpisah. Test tetap; CV ini bukan nested CV.

Pendalaman opsional: menghitung SD sampel

$$s = \sqrt{[\ \Sigma_{r=1..R} (J_r - J \text{ rata-rata})^2 / (R - 1)\ ]}$$

R = 5 pengulangan; **r** indeks pengulangan; **s** simpangan baku. Tanda ² berarti dikalikan dirinya sendiri, dan √ adalah akar kuadrat. Kode menggunakan np.std(..., ddof=1), yaitu pembagi R-1, sesuai "simpangan baku sampel" di laporan.

1. Selisih dari 0,30: -0,04; -0,02; 0; 0,02; 0,04.
2. Kuadrat dan jumlahkan: 0,0016 + 0,0004 + 0 + 0,0004 + 0,0016 = 0,004.
3. Bagi 5-1 = 4: 0,004 / 4 = 0,001.
4. Akar: √0,001 ≈ **0,03162**.

Buka notebook setelah konsepnya nyambung

06_Optuna_CV_dan_OOF.ipynb
validation.repeated_grouped_cv → Hitung ulang ambang dari OOF tersimpan

Cari judul dengan Ctrl+F. Baca konsep, fungsi inti, dan output; helper, log, penyimpanan, serta audit lengkap cukup dirujuk saat perlu.

Rujukan: Bab3: Pembagian Data dan Validasi serta penjelasan objective; 03_Kode/validation.py (mean, std ddof=1, pooled OOF).

LANGKAH 16 / INTI + RUJUKAN

Dari enam skor menjadi confusion matrix

Contoh latihan ini dipakai lagi sampai halaman 19. Hanya satu label dan enam molekul ilustrasi; bukan enam data eksperimen asli.

Molekul	Target y	Skor p	Prediksi p ≥ 0,50	Jenis
A	1	0,90	1	TP
B	0	0,80	1	FP
C	1	0,70	1	TP
D	0	0,60	1	FP
E	1	0,40	0	FN
F	0	0,10	0	TN

TP = 2: positif tercatat dan diprediksi positif. **FP = 2:** tidak tercatat, tetapi diprediksi positif. **FN = 1:** positif tercatat terlewat. **TN = 1:** tidak tercatat dan diprediksi negatif. Total 2 + 2 + 1 + 1 = 6.

Inti: hitung precision, recall, dan F1

Metrik dan rumus	Substitusi angka	Arti hasil
P = TP / (TP + FP)	2 / (2 + 2) = 0,50	Setengah prediksi positif cocok anotasi.
R = TP / (TP + FN)	2 / (2 + 1) = 0,6667	Dua dari tiga positif tercatat ditemukan.
F1 = 2TP / (2TP + FP + FN)	4 / (4 + 2 + 1) = 0,5714	Keseimbangan precision dan recall.
Accuracy = (TP + TN) / total	(2 + 1) / 6 = 0,50	Tiga dari enam keputusan cocok.
Specificity = TN / (TN + FP)	1 / (1 + 2) = 0,3333	Satu dari tiga negatif anotasi dikenali.

P adalah precision, **R** recall. F1 dihitung per label, kemudian dirata-ratakan untuk macro F1; rumusnya setara 2PR/(P+R). **Rujukan:** accuracy dan specificity tetap perlu dimaknai; latihan hitung keduanya boleh dibaca setelah P/R/F1.

Kode memberi precision/recall nol saat penyebutnya tidak ada, dan F1 nol jika P+R = 0. AUROC dan specificity dicatat tidak tersedia pada partisi satu kelas. FP/TN merujuk target anotasi, bukan kepastian sensori.

Buka notebook setelah konsepnya nyambung

07_Evaluasi_dan_Pemilihan.ipynb

metrics.binary_metrics → metrics.summarize → Hitung ulang metrik delapan kandidat

Cari judul dengan Ctrl+F. Baca konsep, fungsi inti, dan output; helper, log, penyimpanan, serta audit lengkap cukup dirujuk saat perlu.

Rujukan: Bab2: eq:precision_recall, penjelasan F1, eq:accuracy_specificity; 03_Kode/metrics.py; validation.f1_from_metrics pada notebook 06.

LANGKAH 17 / INTI + RUJUKAN

Average Precision: apakah positif ada di atas?

AP menilai ranking skor. Kita geser batas penerimaan dari skor tertinggi ke terendah, bukan hanya menilai keputusan pada threshold 0,5.

Rumus AP satu label - Bab II

$$AP_j = \Sigma_k (R_{j,k} - R_{j,k-1}) \times P_{j,k}$$

j: label; **k**: titik threshold saat menuruni ranking; **P**: precision; **R**: recall. $\mathbf{R_{j,0} = 0}$. Maknanya: setiap kenaikan recall dikalikan precision pada titik itu, lalu dijumlahkan.

Pakai lagi enam molekul pada halaman 16

Skor ↓	y	TP / terambil	P	R	Kenaikan R
0,90	1	1 / 1	1	1/3	1/3
0,80	0	1 / 2	1/2	1/3	0
0,70	1	2 / 3	2/3	2/3	1/3
0,60	0	2 / 4	1/2	2/3	0
0,40	1	3 / 5	3/5	1	1/3
0,10	0	3 / 6	1/2	1	0

1. Ada tiga positif, jadi setiap satu positif baru menambah recall sebesar 1/3.
2. Hanya baris target 1 yang memberi kenaikan recall di contoh tanpa skor seri ini.
3. AP = (1/3 × 1) + (1/3 × 2/3) + (1/3 × 3/5).
4. AP = 1/3 + 2/9 + 1/5 = 34/45 ≈ **0,7556**.

Pendalaman opsional - skor seri: skor sama diproses bersama. Dua molekul berskor 0,8 dengan target [1,0] menghasilkan P = 1/2 dan kenaikan R = 1, sehingga AP = **0,5**; urutan penulisan positif lebih dulu tidak membuat AP menjadi 1.

AP bukan "akurasi sekian persen"
Pada halaman 16, accuracy = 0,50, tetapi AP = 0,7556. AP menggunakan ranking skor, accuracy menggunakan keputusan. Kolom bernama auprc pada artefak proyek dihitung dengan average_precision_score, bukan luas trapesium PR.

Buka notebook setelah konsepnya nyambung

07_Evaluasi_dan_Pemilihan.ipynb
metrics.binary_metrics → Hitung ulang metrik delapan kandidat

Cari judul dengan Ctrl+F. Baca konsep, fungsi inti, dan output; helper, log, penyimpanan, serta audit lengkap cukup dirujuk saat perlu.

Rujukan: Bab2: eq:average_precision; 03_Kode/metrics.py: average_precision_score. Jika satu label tanpa positif, AP dicatat nol.

LANGKAH 18 / INTI + RUJUKAN

Macro dan AUROC: dua cara membaca ranking

Macro berarti hitung setiap label terlebih dahulu, lalu rata-ratakan dengan bobot label yang sama. Label yang sering muncul tidak mendapat bobot lebih besar.

Rumus macro AP - Bab II

$$AP_{macro} = (1/L) \Sigma_{j=1..L} AP_j$$

L jumlah label; **j** indeks label. Ilustrasi dua label: AP label A = 34/45 ≈ 0,7556 dari halaman 17, dan AP label B diasumsikan 0,40. Jumlah = 1,1556; bagi dua → **macro AP ≈ 0,5778**. Asumsi label B hanya untuk latihan rata-rata.

Macro F1 bukan F1 dari rata-rata P dan R

Ilustrasi: label A dari halaman 16 mempunyai P = 1/2, R = 2/3, F1 = 4/7. Label B mempunyai TP=1, FP=0, FN=2: P=1, R=1/3, F1=1/2.

1. Macro F1 = (4/7 + 1/2) / 2 = 15/28 ≈ **0,5357**.
2. Rata-rata P = (1/2 + 1)/2 = 0,75; rata-rata R = (2/3 + 1/3)/2 = 0,50.
3. F1 dari kedua rata-rata itu = 2 × 0,75 × 0,50 / 1,25 = **0,60**. Ini bukan macro F1 yang dipakai proyek.

Inti: makna AUROC sebagai ukuran ranking

AUROC adalah luas kurva ROC; kode memakai roc_auc_score. Secara ranking, nilainya mencerminkan seberapa sering skor positif mengungguli negatif, dengan seri berbobot setengah. Metrik ini membutuhkan kedua kelas.

Pendalaman opsional: hitung pasangan satu per satu

Skor positif	Negatif yang skornya lebih rendah	Menang
0,90	0,80; 0,60; 0,10	3
0,70	0,60; 0,10	2
0,40	0,10	1

Ada 3 positif × 3 negatif = **9 pasangan**. Positif menang 3 + 2 + 1 = 6 pasangan, sehingga AUROC = 6/9 ≈ **0,6667**.

AP dan AUROC melihat ranking dari sudut berbeda. Mengubah threshold keputusan saja tidak mengubah keduanya. Untuk label tidak seimbang, AP membantu fokus pada ketepatan dan penemuan anotasi positif; itulah kriteria seleksi proyek.

Buka notebook setelah konsepnya nyambung

07_Evaluasi_dan_Pemilihan.ipynb
metrics.binary_metrics → metrics.summarize

Cari judul dengan Ctrl+F. Baca konsep, fungsi inti, dan output; helper, log, penyimpanan, serta audit lengkap cukup dirujuk saat perlu.

Rujukan: Bab2: eq:macro_ap, Macro F1, AUROC; 03_Kode/metrics.py; validation.prediction_diagnostics pada notebook 06.

LANGKAH 19 / INTI + RUJUKAN

Threshold OOF: tambahan, bukan hasil utama

Threshold utama penelitian dan aplikasi adalah 0,5. Threshold per label yang dipilih dari OOF dilaporkan sebagai analisis tambahan.

Inti: OOF train → pilih → kunci → test

Untuk setiap label, pilih F1 terbesar dari keputusan atas rata-rata skor OOF lima seed pada train. Threshold terpilih **dikunci sebelum diterapkan pada test**; test tidak digunakan untuk memilih ulang. Aturan utama penelitian dan aplikasi tetap 0,5.

Rujukan implementasi: grid **0,05-0,95**, langkah **0,05**. Jika F1 seri, pilih threshold paling dekat 0,5; jika masih seri, pilih yang lebih besar. Detail ini disimpan untuk reproduksi, bukan hafalan seluruh nilai grid.

Ilustrasi dengan data halaman 16

Threshold	TP	FP	FN	Hitungan F1
0,90	1	0	2	2/(2+0+2) = 0,50
0,70	2	1	1	4/(4+1+1) = 0,6667
0,50	2	2	1	4/(4+2+1) = 0,5714
0,40	3	2	0	6/(6+2+0) = 0,75

Tabel hanya menampilkan empat nilai grid. Pada ilustrasi ini, threshold 0,15-0,40 mengambil lima baris teratas dengan F1 = 0,75. Aturan seri memilih **0,40**, yang paling dekat 0,50. Pemilihan sebenarnya memakai OOF train.

Hasil asli LightGBM D pada test

Metrik	Threshold 0,5	Threshold OOF
Macro F1	0,293156	0,330419
Macro precision	0,213862	0,303265
Macro recall	0,515089	0,411890

F1 dan precision naik, tetapi recall turun. Ini tradeoff: prediksi lebih selektif, sebagian positif tercatat lebih banyak terlewat. AP test tetap **0,310531** karena skor dan ranking tidak berubah.

OOF masih berasal dari proses pengembangan yang terkait seleksi parameter; ini tidak bebas bias seleksi. Penyesuaian threshold tidak menjamin F1 test naik pada semua kandidat.

Buka notebook setelah konsepnya nyambung

06_Optuna_CV_dan_OOF.ipynb
validation.f1_from_metrics → validation.select_validation_thresholds → Hitung ulang ambang dari OOF tersimpan

Cari judul dengan Ctrl+F. Baca konsep, fungsi inti, dan output; helper, log, penyimpanan, serta audit lengkap cukup dirujuk saat perlu.

Rujukan: Bab3: Evaluasi; lampiran rincian_reproduksi dan evaluasi_tambahan; 03_Kode/validation.py.

LANGKAH 20 / INTI + RUJUKAN

Hasil akhir: mengapa LightGBM D?

Semua angka pada halaman ini adalah hasil asli eksperimen utama, dibulatkan enam desimal. Pilihan berasal dari validasi, bukan dari pemilihan skor test tertinggi.

Kandidat	Mean AP CV	AP test	F1 test (0,5)
XGBoost A	0,249589	0,249043	0,274899
XGBoost B	0,277412	0,288125	0,311835
XGBoost C	0,267049	0,273029	0,270369
XGBoost D	0,296959	0,308827	0,305902
LightGBM A	0,251681	0,252837	0,277184
LightGBM B	0,283211	0,296380	0,320721
LightGBM C	0,269114	0,276461	0,252220
LightGBM D	**0,299731**	**0,310531**	**0,293156**

1. Kriteria: rata-rata macro AP validasi lima seed tertinggi.
2. Pemenang: LightGBM D = 0,299731; XGBoost D = 0,296959.
3. Selisih: 0,299731 - 0,296959 ≈ **0,002772** berdasarkan angka presisi penuh. Keunggulan tipis dan deskriptif; tidak ada bukti signifikansi statistik atau keunggulan universal.

Apa yang didukung hasilnya?

Tambahan deskriptor meningkatkan AP pada B-A dan D-C untuk kedua algoritma. Tuning meningkatkan AP pada C-A dan D-B. Namun macro F1 pada threshold 0,5 justru lebih rendah setelah tuning; LightGBM B mencapai F1 0,320721, lebih tinggi daripada D.

Kalau dosen bertanya "bagus atau belum?"
"LightGBM D paling baik menurut kriteria AP validasi di eksperimen ini. AP test 0,310531 bukan akurasi 31%. Performa bergantung label, anotasi belum lengkap, dan generalisasi eksternal belum dibuktikan."

Jebakan accuracy: label accuracy LightGBM D = 0,923660. Prediksi semua nol mencapai 0,960970, tetapi recall dan F1 nol. Accuracy tinggi sendirian belum membuktikan model berguna untuk menemukan aroma.

Buka notebook setelah konsepnya nyambung

07_Evaluasi_dan_Pemilihan.ipynb
Baca delapan kandidat dan hasil utama → Reproduksi pilihan dari CV tersimpan → Baca delta dan cek kesamaan cakupan

Cari judul dengan Ctrl+F. Baca konsep, fungsi inti, dan output; helper, log, penyimpanan, serta audit lengkap cukup dirujuk saat perlu.

Rujukan: Bab4: Perbandingan Delapan Kandidat; artefak asli comparison_all.csv dan selection_frozen.json, juga disalin ke 04_Hasil.

LANGKAH 21 / INTI + RUJUKAN

Dari model tersimpan ke prediksi molekul

Prediksi baru memakai model final yang sudah dilatih. Tidak ada training ulang hanya karena kamu memasukkan satu SMILES.

Tahap	Input → proses → output
1. Masukan	SMILES satu molekul → periksa struktur → objek molekul valid.
2. Fitur	Struktur → Morgan 2.048 + delapan deskriptor dalam urutan tetap → satu baris berisi 2.056 angka.
3. Inferensi	Fitur → 109 classifier LightGBM D tersimpan → 109 skor.
4. Keputusan	Skor → bandingkan dengan 0,5 → daftar label yang lolos.

Notebook 08 memperlihatkan inferensi Python dari model tersimpan. Pada Essenza, **RDKit dan 109 model LightGBM asli dijalankan di komputer lokal**. Android mengirim SMILES melalui USB, lalu menerima skor untuk ditampilkan dan disimpan. Urutan fitur, label, dan threshold mengikuti model hasil pelatihan.

Integrasi model asli telah diperiksa melalui layanan lokal dan contoh prediksi pada Android. Pengoperasian ini tetap memerlukan komputer dan koneksi USB. Ini belum membuktikan manfaat pengguna, validitas sensori, atau kesiapan produksi. SMILES valid juga tidak otomatis berarti berada dalam domain bahan pewangi yang dipelajari.

Buka notebook setelah konsepnya nyambung

08_Prediksi_Molekul.ipynb
Temukan hasil utama dan kontrak model → inference.predict → Jalankan prediksi nyata → Lihat keputusan positif

Cari judul dengan Ctrl+F. Baca konsep, fungsi inti, dan output; helper, log, penyimpanan, serta audit lengkap cukup dirujuk saat perlu.

Rujukan: Bab3: Implementasi Essenza; Bab4: pengujian aplikasi; 03_Kode/inference.py. Notebook dan layanan aplikasi memakai model hasil pelatihan yang sama; pengujian Android melalui layanan prediksi lokal tetap diperiksa terpisah.

Pegangan sumber ketika ada tulisan yang berbeda

Laporan utama: SKRIPSI.tex → src/2.Isi/Bab1.tex sampai Bab5.tex, serta lampiran yang disertakan. Lokasi:

C: / Users / ACER / Documents / Marvel / Skripsi / Laporan Skripsi / 2521_skripsi_Marvel_Kevin_Nathanael

Kode: KODE_ML/03_Kode; konfigurasi: config/experiment.json. **Hasil:** results.py menunjuk arsip utama yang dikunci; salinan belajar di 04_Hasil. **05_Referensi/Laporan** adalah snapshot lama dan dapat berbeda dari laporan aktif. PDF ini memakai laporan utama, bukan snapshot tersebut.

Rumus bernomor yang dicakup: eq:label_threshold; eq:bobot_kelas_seimbang; eq:average_precision; eq:macro_ap; eq:precision_recall; eq:accuracy_specificity; eq:optuna_objective. F1, rata-rata seed, dan SD mengikuti uraian laporan serta operasi kode. Tidak menambah rumus loss/gradient sebagai rumus laporan.

LANGKAH 22 / INTI + RUJUKAN

Latihan sidang: ceritakan tanpa membaca

Jawab dengan pola: keputusan yang dipakai → alasannya → batas klaimnya. Tidak perlu menghafal seluruh baris source.

Pertanyaan dosen	Contoh jawaban singkat
Mengapa multi-label?	Satu molekul bisa memiliki beberapa label aroma. Binary Relevance melatih satu classifier untuk tiap label.
Mengapa Morgan + 8?	Morgan menangkap pola lokal struktur; delapan deskriptor melengkapi sifat molekul. Manfaat paketnya diuji lewat A-D, bukan diasumsikan optimal.
Mengapa tidak split acak per baris?	Kelompok mencegah identitas yang ditentukan protokol tersebar ke fitting dan evaluasi. Ini belum menjamin pemisahan semua kemiripan atau scaffold.
Mengapa AP?	Label tidak seimbang. AP menilai ranking dengan precision dan recall; macro memberi bobot sama ke setiap label.
Mengapa bukan model F1 tertinggi?	Kriteria seleksi ditetapkan memakai AP validasi. F1 pada threshold 0,5 adalah ukuran pendukung dan menunjukkan tradeoff.
Apakah 0 berarti aromanya tidak ada?	Nol berarti tidak tercatat pada target, bukan negatif sensori terverifikasi.
Apakah test sepenuhnya baru?	Pada run utama, pilihan dikunci sebelum evaluasi test. Namun test pernah diakses dalam pengembangan sebelumnya, sehingga hasilnya eksploratori.
Apa keterbatasan terbesarnya?	Anotasi tidak lengkap, imbalance, fitur identik dengan target berbeda, CV bukan nested, serta belum ada validasi eksternal/sensori.

Checklist inti sebelum sidang

□ Bisa menjelaskan gap ilmiah, alasan memilih dua model, dan batas tanpa RF.
□ Bisa menggambar alur SMILES → fitur → 109 classifier → skor → label.
□ Bisa menghitung bobot, threshold, TP/FP/FN/TN, P/R/F1, AP, macro AP, dan mean CV; menjelaskan makna SD dan AUROC.
□ Bisa menunjuk notebook, fungsi inti, serta lokasi bukti tiap tahap.
□ Bisa membedakan ilustrasi, hasil utama, serta analisis tambahan.
□ Bisa menjelaskan alasan LightGBM D dipilih dan batas hasilnya.

Pendalaman opsional: hitung akar SD (halaman 15), enumerasi pasangan AUROC (18), dan uraian RF (6). Helper, log, penyimpanan, serta audit lengkap cukup dibuka saat diperlukan.

Latihan terakhir, sekitar satu menit
Ceritakan gap, alur penelitian, satu hasil, dan dua keterbatasannya. Batas tanpa RF cukup dijawab singkat. Ulangi halaman terkait jika masih tersendat.

Peta bagian notebook tersimpan juga di 01_Materi/Peta_Notebook.md. Untuk pertanyaan detail implementasi, buka notebook yang dirujuk pada halaman terkait. Materi lama disimpan sebagai referensi historis di 05_Referensi.

Peta 33 referensi skripsi

33 dari 33 entri aktif digunakan. Rantai input SKRIPSI.tex, pustaka.bib, 33 entri daftar pustaka, dan tautan sitasi pada PDF skripsi telah dicocokkan. Tidak ditemukan entri aktif tanpa sitasi atau sitasi tanpa entri.

Cara membaca nomor halaman
"7 (PDF 23)" berarti halaman tercetak 7 berada pada urutan ke-23 dalam PDF **skripsi**, dihitung dari sampul. "Daftar pustaka" menunjukkan lokasi entri, sedangkan "Sitasi" menunjukkan tempat sumber dikutip. Angka tersebut bukan halaman artikel sumber.

Nomor [1]-[33] di bagian ini mengikuti daftar pustaka skripsi. Rujukan lokal [1], [2], dan seterusnya pada materi inti halaman 1-22 panduan memakai penomoran tersendiri. Jangan menyamakannya.

Ref. skripsi	Fokus bacaan	PDF panduan
[1-3]	Pyrfume dan studi aroma utama	24
[4-6]	Studi aroma, XGBoost, dan LightGBM	25
[7-9]	Optuna, precision-recall, dan bias seleksi	26
[10-12]	Snapshot data, struktur-aroma, dan SMILES	27
[13-15]	Fingerprint dan deskriptor RDKit	28
[16-18]	Multi-label, kalibrasi, dan F1	29
[19-21]	Threshold, parameter, dan bobot	30
[22-24]	TPE, startup, dan pemisahan kelompok	31
[25-27]	Fold, scaffold, dan kurva model	32
[28-30]	AP, React Native, dan FastAPI	33
[31-33]	Kurasi, validasi berulang, dan variasi	34

Batas pemetaan. Fungsi sumber diringkas dari klaim yang disitasi dalam naskah aktif. "Terpakai" tidak berarti seluruh artikel telah dibaca penuh atau semua klaim telah diverifikasi ulang. Batas akses yang relevan, khususnya Tyagi, tetap dijelaskan.

Versi halaman. Acuan: PDF skripsi 94 halaman, sesuai sumber LaTeX yang diperiksa pada 9 November 2026. Bab I dimulai pada PDF 17; daftar pustaka pada halaman tercetak 56-59 (PDF 72-75). Susunan ulang skripsi dapat mengubah nomor ini. Versi teks dan jejak berkas tersedia di 05_Referensi/PETA_REFERENSI_SKRIPSI.md.

Referensi [1]-[3]

Halaman pada kartu adalah halaman skripsi. Nomor PDF panduan ada pada footer.

Ref. skripsi [1] - Hamel dkk. (2024) - Pyrfume

Pyrfume: A Window to the World's Olfactory Data

Dipakai untuk: Mendukung latar belakang integrasi data olfaksi dan penjelasan hubungan tabel molekul, stimulus, serta pengamatan. Juga menjadi rujukan platform untuk pemilihan lima sumber data.

Sitasi: 1 (PDF 17); 2 (PDF 18); 7 (PDF 23); 17 (PDF 33). **Daftar pustaka:** 56 (PDF 72).

Kuasai saat sidang: Bedakan Pyrfume sebagai platform dari lima arsip yang benar-benar digunakan dalam penelitian.

Batas klaim: Jumlah dataset dan senyawa dalam publikasi Pyrfume bukan jumlah data akhir skripsi.

Key BibTeX: hamel2024

Ref. skripsi [2] - Saini dan Ramanathan (2022)

Predicting Odor from Molecular Structure: A Multi-Label Classification Approach

Dipakai untuk: Mendukung perumusan prediksi aroma sebagai multi-label, pengenalan Binary Relevance dan Classifier Chains, serta ringkasan penelitian terdahulu yang menggunakan micro-F1.

Sitasi: 1 (PDF 17); 5 (PDF 21); 6 (PDF 22). **Daftar pustaka:** 56 (PDF 72).

Kuasai saat sidang: Jelaskan mengapa satu molekul dapat memiliki beberapa label dan bedakan micro-F1 dari macro-F1.

Batas klaim: Skor micro-F1 artikel tidak dapat dibandingkan langsung dengan macro-F1 skripsi.

Key BibTeX: saini2022

Ref. skripsi [3] - Suh dkk. (2025)

A Comparative Study of Machine Learning Models on Molecular Fingerprints for Odor Decoding

Dipakai untuk: Menjadi studi pembanding utama dan dasar posisi penelitian: Morgan, gugus fungsi, dan delapan deskriptor diuji terpisah pada studi acuan. Skripsi menguji penambahan deskriptor pada Morgan melalui perbandingan internal.

Sitasi: 1 (PDF 17); 5 (PDF 21); 6 (PDF 22). **Daftar pustaka:** 56 (PDF 72).

Kuasai saat sidang: Jelaskan perbedaan representasi, data, label, pembagian, dan metrik pada tabel posisi penelitian.

Batas klaim: Skripsi bukan replikasi persis; AUPRC artikel tidak otomatis identik dengan implementasi AP skripsi.

Key BibTeX: suh2025

Referensi [4]-[6]

Halaman pada kartu adalah halaman skripsi. Nomor PDF panduan ada pada footer.

Ref. skripsi [4] - Tyagi dkk. (2024)

XGBoost Odor Prediction Model: Finding the Structure-Odor Relationship of Odorant Molecules Using the Extreme Gradient Boosting Algorithm

Dipakai untuk: Mendukung konteks penggunaan fitur fisikokimia dan XGBoost untuk prediksi aroma. Tabel kajian memuat jumlah molekul, tujuh target aroma, PCA, serta precision dan sensitivity sebagai metrik studi tersebut.

Sitasi: 1 (PDF 17); 6 (PDF 22); 7 (PDF 23). **Daftar pustaka:** 56 (PDF 72).

Kuasai saat sidang: Bedakan tujuh target dan fitur studi Tyagi dari 109 label dan paket fitur skripsi.

Batas klaim: Uraian dibatasi informasi abstrak yang diperiksa; jangan menambahkan detail split atau averaging yang belum terverifikasi.

Key BibTeX: tyagi2024

Ref. skripsi [5] - Chen dan Guestrin (2016) - XGBoost

XGBoost: A Scalable Tree Boosting System

Dipakai untuk: Menjadi landasan algoritma XGBoost: boosting pohon, penanganan data jarang, regularisasi, serta makna min_child_weight dan gamma. Mendukung alasan membandingkannya dengan LightGBM.

Sitasi: 1 (PDF 17); 9 (PDF 25); 10 (PDF 26). **Daftar pustaka:** 56 (PDF 72).

Kuasai saat sidang: Jelaskan penambahan pohon bertahap, kendali kompleksitas, dan mengapa min_child_weight bukan jumlah minimum sampel.

Batas klaim: Paper algoritma tidak membuktikan XGBoost paling unggul pada dataset aroma skripsi.

Key BibTeX: chen2016

Ref. skripsi [6] - Ke dkk. (2017) - LightGBM

LightGBM: A Highly Efficient Gradient Boosting Decision Tree

Dipakai untuk: Menjadi landasan algoritma LightGBM dan pertumbuhan pohon leaf-wise. Bersama sumber XGBoost, mendukung pemilihan dua algoritma boosting dengan mekanisme pertumbuhan dan kendali kompleksitas berbeda.

Sitasi: 1 (PDF 17); 10 (PDF 26). **Daftar pustaka:** 56 (PDF 72).

Kuasai saat sidang: Jelaskan pemilihan daun yang dibagi dan mengapa cabang pohon dapat memiliki kedalaman berbeda.

Batas klaim: Definisi parameter implementasi dirujuk terpisah ke dokumentasi LightGBM [20].

Key BibTeX: ke2017

Referensi [7]-[9]

Halaman pada kartu adalah halaman skripsi. Nomor PDF panduan ada pada footer.

Ref. skripsi [7] - Akiba dkk. (2019) - Optuna

Optuna: A Next-generation Hyperparameter Optimization Framework

Dipakai untuk: Mendukung penggunaan Optuna sebagai framework optimasi hiperparameter dan pengertian ruang pencarian, trial, serta studi. Menjadi rujukan metode pencarian pada rancangan kandidat C dan D.

Sitasi: 1 (PDF 17); 10 (PDF 26); 24 (PDF 40). **Daftar pustaka:** 56 (PDF 72).

Kuasai saat sidang: Bedakan framework Optuna, algoritma sampler TPE, dan objektif macro AP yang ditetapkan penelitian.

Batas klaim: Anggaran delapan jam adalah keputusan rancangan penelitian, bukan standar yang ditetapkan paper ini.

Key BibTeX: akiba2019

Ref. skripsi [8] - Saito dan Rehmsmeier (2015)

The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets

Dipakai untuk: Mendukung alasan menggunakan penilaian precision-recall ketika kelas tidak seimbang. Menghubungkan masalah sedikitnya contoh positif dengan prioritas penilaian kemampuan menemukan label positif.

Sitasi: 1 (PDF 17); 12 (PDF 28). **Daftar pustaka:** 56 (PDF 72).

Kuasai saat sidang: Jelaskan mengapa accuracy saja dapat menutupi kegagalan mengenali kelas positif yang jarang.

Batas klaim: Rumus AP dan implementasi perhitungannya dirujuk ke dokumentasi [28], bukan semata-mata artikel ini.

Key BibTeX: saito2015

Ref. skripsi [9] - Cawley dan Talbot (2010)

On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation

Dipakai untuk: Mendukung pembahasan bias pemilihan model, pemisahan pemilihan parameter dari evaluasi akhir, serta kebutuhan membatasi interpretasi repeated CV dan pemilihan threshold OOF.

Sitasi: 1 (PDF 17); 11 (PDF 27); 27 (PDF 43). **Daftar pustaka:** 56 (PDF 72).

Kuasai saat sidang: Jelaskan mengapa mengulang CV tidak otomatis membuat evaluasi menjadi nested CV atau independen.

Batas klaim: Prosedur skripsi belum menghilangkan bias seleksi; riwayat akses test tetap menjadi keterbatasan.

Key BibTeX: cawley2010

Referensi [10]-[12]

Halaman pada kartu adalah halaman skripsi. Nomor PDF panduan ada pada footer.

Ref. skripsi [10] - Pyrfume contributors - snapshot lima sumber

Pyrfume-data: GoodScents, IFRA 2019, Leffingwell, Arctander 1960, and Sigma 2014 archives

Dipakai untuk: Mengidentifikasi arsip data GoodScents, IFRA 2019, Leffingwell, Arctander 1960, dan Sigma 2014 pada commit tertentu. Mendukung batas sumber serta penjelasan pemilihan dan pengumpulan data.

Sitasi: 2 (PDF 18); 17 (PDF 33). **Daftar pustaka:** 57 (PDF 73).

Kuasai saat sidang: Tunjukkan snapshot dan manifest untuk menelusuri versi arsip yang benar-benar digunakan.

Batas klaim: Fungsinya adalah provenance versi data; berbeda dari artikel pengantar platform Pyrfume [1].

Key BibTeX: pyrfumeFive2026

Ref. skripsi [11] - Keller dkk. (2017)

Predicting Human Olfactory Perception from Chemical Features of Odor Molecules

Dipakai untuk: Mendukung dasar hubungan struktur kimia dan persepsi aroma: karakter olfaksi dapat dipelajari melalui fitur molekul. Dipakai pada pembukaan kajian hubungan struktur-aroma.

Sitasi: 5 (PDF 21). **Daftar pustaka:** 57 (PDF 73).

Kuasai saat sidang: Jelaskan mengapa fitur molekul layak dijadikan masukan prediksi tanpa menyatakan model mencium secara langsung.

Batas klaim: Tidak membuktikan validitas sensori, manfaat pengguna, atau prediksi aroma campuran pada Essenza.

Key BibTeX: keller2017

Ref. skripsi [12] - Weininger (1988) - SMILES

SMILES, a Chemical Language and Information System. 1. Introduction to Methodology and Encoding Rules

Dipakai untuk: Mendukung definisi SMILES sebagai notasi teks untuk atom, ikatan, percabangan, dan cincin. Memberi landasan representasi struktur sebelum ekstraksi fitur.

Sitasi: 7 (PDF 23). **Daftar pustaka:** 57 (PDF 73).

Kuasai saat sidang: Jelaskan hubungan string SMILES dengan graf molekul; penulisan berbeda dapat menyatakan struktur yang sama.

Batas klaim: Aturan kanonisasi dan perilaku parser aktual bergantung pada perangkat lunak yang digunakan.

Key BibTeX: weininger1988

Referensi [13]-[15]

Halaman pada kartu adalah halaman skripsi. Nomor PDF panduan ada pada footer.

Ref. skripsi [13] - Rogers dan Hahn (2010) - ECFP

Extended-Connectivity Fingerprints

Dipakai untuk: Mendukung konsep extended-connectivity fingerprint dan hubungannya dengan Morgan: lingkungan atom dipetakan menjadi representasi pola struktur. Menjadi dasar penjelasan hashing dan kemungkinan tabrakan bit.

Sitasi: 7 (PDF 23). **Daftar pustaka:** 57 (PDF 73).

Kuasai saat sidang: Jelaskan radius lingkungan atom dan mengapa satu bit tidak selalu mewakili satu pola yang unik.

Batas klaim: Parameter RDKit yang benar-benar dipakai harus dibaca dari kode dan dokumentasi [14].

Key BibTeX: rogers2010

Ref. skripsi [14] - RDKit - Molecular Fingerprint Generators

Molecular Fingerprint Generators: RDKit Documentation

Dipakai untuk: Mendukung API perhitungan Morgan dan makna radius, panjang fingerprint, serta kiralitas. Digunakan dalam teori fitur, konfigurasi radius 2 dan 2.048 bit, serta contoh ekstraksi fitur vanilin.

Sitasi: 8 (PDF 24); 21 (PDF 37). **Daftar pustaka:** 57 (PDF 73).

Kuasai saat sidang: Tunjukkan parameter eksplisit pada kode; bit bernilai satu menyatakan aktivasi pola, bukan label aroma.

Batas klaim: Angka bit aktif contoh berasal dari perhitungan proyek; dokumentasi daring dapat berubah versinya.

Key BibTeX: rdkitgenerator2026

Ref. skripsi [15] - RDKit - Descriptor Calculation

Getting Started with the RDKit in Python: Descriptor Calculation

Dipakai untuk: Mendukung perhitungan dan makna deskriptor molekuler, tabel delapan deskriptor, serta pembentukan fitur gabungan Morgan dan deskriptor dalam metode penelitian.

Sitasi: 8 (PDF 24); 21 (PDF 37). **Daftar pustaka:** 57 (PDF 73).

Kuasai saat sidang: Jelaskan sifat yang dirangkum delapan deskriptor dan pentingnya urutan fitur yang konsisten.

Batas klaim: Dokumentasi tidak membuktikan paket delapan fitur optimal atau bahwa setiap deskriptor meningkatkan hasil.

Key BibTeX: rdkitdescriptors2026

Referensi [16]-[18]

Halaman pada kartu adalah halaman skripsi. Nomor PDF panduan ada pada footer.

Ref. skripsi [16] - Tsoumakas dan Katakis (2007)

Multi-Label Classification: An Overview

Dipakai untuk: Mendukung definisi klasifikasi multi-label dan penggunaan Binary Relevance, yaitu satu pengklasifikasi biner untuk setiap label. Menjadi dasar bentuk target dan organisasi model penelitian.

Sitasi: 8 (PDF 24); 22 (PDF 38). **Daftar pustaka:** 57 (PDF 73).

Kuasai saat sidang: Bedakan multi-label dari multiclass dan jelaskan keterbatasan model terpisah dalam mempelajari hubungan antarlabel.

Batas klaim: Makna target nol sebagai anotasi tidak tercatat adalah batas dataset skripsi, bukan bukti sensoris negatif.

Key BibTeX: tsoumakas2007

Ref. skripsi [17] - scikit-learn - Probability Calibration

Probability Calibration

Dipakai untuk: Mendukung pengertian kalibrasi, yaitu kesesuaian skor dengan frekuensi kejadian yang diamati. Dipakai untuk membatasi interpretasi skor keluaran model pada pembahasan Binary Relevance.

Sitasi: 9 (PDF 25). **Daftar pustaka:** 57 (PDF 73).

Kuasai saat sidang: Bedakan skor model, keputusan threshold, intensitas aroma, dan probabilitas yang telah dikalibrasi.

Batas klaim: Skripsi tidak melaporkan eksperimen kalibrasi; skor tidak boleh disebut peluang persepsi manusia yang terverifikasi.

Key BibTeX: sklearncalibration2026

Ref. skripsi [18] - Lipton dkk. (2014)

Thresholding Classifiers to Maximize F1 Score

Dipakai untuk: Mendukung hubungan pilihan threshold dengan F1 dan kemungkinan kebutuhan batas berbeda antarlabel. Menjadi dasar konseptual analisis tambahan threshold per label menggunakan skor OOF training.

Sitasi: 9 (PDF 25); 27 (PDF 43). **Daftar pustaka:** 57 (PDF 73).

Kuasai saat sidang: Jelaskan mengapa threshold 0,5 tidak otomatis memaksimalkan F1 dan mengapa threshold dapat berbeda antarlabel.

Batas klaim: Tidak membuktikan grid threshold skripsi optimal; hasil utama tetap menggunakan threshold tetap 0,5.

Key BibTeX: lipton2014

Referensi [19]-[21]

Halaman pada kartu adalah halaman skripsi. Nomor PDF panduan ada pada footer.

Ref. skripsi [19] - scikit-learn - Tuning the Decision Threshold

Tuning the Decision Threshold for Class Prediction

Dipakai untuk: Mendukung pemilihan threshold melalui data validasi atau prediksi validasi silang serta peringatan agar tidak memilihnya memakai prediksi data yang melatih model yang sama. Dirujuk pada analisis OOF.

Sitasi: 9 (PDF 25); 27 (PDF 43). **Daftar pustaka:** 57 (PDF 73).

Kuasai saat sidang: Jelaskan urutan skor OOF training, pemilihan threshold, penguncian, lalu penerapan pada test.

Batas klaim: Implementasi pencarian threshold skripsi berasal dari kode sendiri; sitasi tidak berarti memakai kelas tuner scikit-learn.

Key BibTeX: sklearnthreshold2026

Ref. skripsi [20] - LightGBM 4.6.0 - Parameters

Parameters: LightGBM 4.6.0 Documentation

Dipakai untuk: Mendukung makna num_leaves dan min_child_samples untuk kendali kompleksitas, serta syarat subsample_freq agar subsampling baris aktif ketika subsample kurang dari satu.

Sitasi: 10 (PDF 26); 25 (PDF 41). **Daftar pustaka:** 58 (PDF 74).

Kuasai saat sidang: Bedakan parameter yang dicari Optuna dari subsample_freq=1 yang ditetapkan tetap.

Batas klaim: Makna parameter tidak membuktikan rentang pencarian yang dipilih merupakan rentang terbaik.

Key BibTeX: lightgbmparameters2026

Ref. skripsi [21] - scikit-learn - compute_sample_weight

compute_sample_weight: Class-Balanced Sample Weights

Dipakai untuk: Mendukung formula bobot kelas seimbang untuk klasifikasi biner, $w_c=N/(2N_c)$. Uraian menjelaskan bobot lebih besar bagi kelas yang lebih sedikit dan perhitungan dari bagian fitting.

Sitasi: 10 (PDF 26). **Daftar pustaka:** 58 (PDF 74).

Kuasai saat sidang: Hitung contoh bobot dua kelas dan jelaskan mengapa statistik validasi atau test tidak ikut menghitungnya.

Batas klaim: Semua kondisi memakai bobot; tidak ada eksperimen yang membuktikan keunggulan terhadap kondisi tanpa bobot.

Key BibTeX: sklearnweights2026

Referensi [22]-[24]

Halaman pada kartu adalah halaman skripsi. Nomor PDF panduan ada pada footer.

Ref. skripsi [22] - Bergstra dkk. (2011) - TPE

Algorithms for Hyper-Parameter Optimization

Dipakai untuk: Mendukung dasar algoritma Tree-structured Parzen Estimator yang menggunakan hasil trial sebelumnya untuk mengarahkan kombinasi parameter berikutnya. Melengkapi paper framework Optuna.

Sitasi: 10 (PDF 26); 24 (PDF 40). **Daftar pustaka:** 58 (PDF 74).

Kuasai saat sidang: Bedakan pencarian awal acak dari pemilihan berikutnya yang dipandu riwayat nilai objektif.

Batas klaim: Jumlah 10 trial awal dan perilaku versi sampler dirujuk ke dokumentasi Optuna [23].

Key BibTeX: bergstra2011

Ref. skripsi [23] - Optuna 4.5.0 - TPESampler

TPESampler: Tree-Structured Parzen Estimator

Dipakai untuk: Mendukung perilaku tahap awal sampler: sampling acak sebelum jumlah trial selesai mencapai batas startup, kemudian pemanfaatan riwayat oleh TPE. Dirujuk dalam teori dan rincian reproduksi pada lampiran.

Sitasi: 10 (PDF 26); 73 (PDF 89). **Daftar pustaka:** 58 (PDF 74).

Kuasai saat sidang: Jelaskan perbedaan resep yang dimasukkan pada trial pertama dan parameter yang masih disampling.

Batas klaim: Nilai aktual dan urutan trial tetap harus ditelusuri pada konfigurasi serta log penelitian.

Key BibTeX: optunatpe2026

Ref. skripsi [24] - scikit-learn - GroupShuffleSplit

GroupShuffleSplit: scikit-learn 1.6 Documentation

Dipakai untuk: Mendukung pemisahan training dan test berdasarkan kelompok. Proporsi test dihitung terhadap jumlah kelompok, sehingga persentase molekul test tidak harus tepat sama dengan proporsi yang diminta.

Sitasi: 11 (PDF 27); 20 (PDF 36). **Daftar pustaka:** 58 (PDF 74).

Kuasai saat sidang: Jelaskan definisi kelompok historis dan mengapa anggota kelompok tidak boleh tersebar ke training dan test.

Batas klaim: Splitter tidak mendefinisikan kemiripan kimia; aturan pembentukan kelompok berasal dari kode penelitian.

Key BibTeX: sklearngroupshuffle2026

Referensi [25]-[27]

Halaman pada kartu adalah halaman skripsi. Nomor PDF panduan ada pada footer.

Ref. skripsi [25] - scikit-learn - StratifiedGroupKFold

StratifiedGroupKFold: scikit-learn 1.6 Documentation

Dipakai untuk: Mendukung validasi silang yang menjaga anggota kelompok tetap bersama sambil mengusahakan proporsi kelas serupa. Digunakan dalam penjelasan fold per label pada data training.

Sitasi: 11 (PDF 27); 20 (PDF 36). **Daftar pustaka:** 58 (PDF 74).

Kuasai saat sidang: Bedakan stratifikasi kelas dari pemisahan kelompok dan jelaskan pemeriksaan keberadaan kedua kelas pada fold.

Batas klaim: Lima fold adalah keputusan rancangan dan kelayakan data; dokumentasi tidak menyatakannya optimal untuk aroma.

Key BibTeX: sklearnstratifiedgroup2026

Ref. skripsi [26] - Wu dkk. (2018) - MoleculeNet

MoleculeNet: A Benchmark for Molecular Machine Learning

Dipakai untuk: Mendukung penjelasan scaffold split sebagai evaluasi pada kerangka utama molekul yang berbeda. Menjadi konteks pembanding bagi pembagian kelompok yang digunakan dalam skripsi.

Sitasi: 11 (PDF 27). **Daftar pustaka:** 58 (PDF 74).

Kuasai saat sidang: Jelaskan perbedaan kelompok struktur atau fingerprint identik dengan pemisahan berdasarkan scaffold.

Batas klaim: Skripsi tidak memakai scaffold split dan tidak menjamin seluruh molekul mirip terpisah antara training dan test.

Key BibTeX: wu2018

Ref. skripsi [27] - scikit-learn - Early stopping in Gradient Boosting

Early stopping in Gradient Boosting

Dipakai untuk: Mendukung interpretasi kurva training dan validation terhadap jumlah pohon: perbaikan training yang tidak diikuti validation dapat mengindikasikan overfitting.

Sitasi: 11 (PDF 27). **Daftar pustaka:** 58 (PDF 74).

Kuasai saat sidang: Jelaskan sumbu kurva dan mengapa pola kurva harus dibaca bersama hasil validasi serta karakteristik data.

Batas klaim: Sumber dipakai untuk interpretasi kurva; penelitian tidak menerapkan early stopping pada tuning.

Key BibTeX: sklearnboostingcurve2026

Referensi [28]-[30]

Halaman pada kartu adalah halaman skripsi. Nomor PDF panduan ada pada footer.

Ref. skripsi [28] - scikit-learn - average_precision_score

average_precision_score: scikit-learn 1.6 Documentation

Dipakai untuk: Mendukung definisi AP sebagai jumlah kenaikan recall yang dibobot precision dan agregasi macro dengan bobot label yang sama. Menjadi rujukan rumus serta implementasi metrik AP.

Sitasi: 12 (PDF 28). **Daftar pustaka:** 58 (PDF 74).

Kuasai saat sidang: Hitung AP sederhana, lalu bedakan macro AP, micro averaging, accuracy, dan luas PR dengan trapesium.

Batas klaim: AP tidak menggunakan satu threshold keputusan tetap dan tidak identik dengan accuracy.

Key BibTeX: sklearnap2026

Ref. skripsi [29] - Meta Platforms - React Native

React Native: A framework for building native apps using React

Dipakai untuk: Mendukung fungsi React Native sebagai framework komponen antarmuka aplikasi seluler. Dirujuk dalam landasan integrasi Android dengan layanan prediksi lokal.

Sitasi: 14 (PDF 30). **Daftar pustaka:** 58 (PDF 74).

Kuasai saat sidang: Jelaskan tugas Android dalam mengirim input, menampilkan hasil, serta menyimpan Riwayat dan Koleksi.

Batas klaim: Dokumentasi framework bukan bukti bahwa estimator atau RDKit berjalan di Android.

Key BibTeX: reactnative2024

Ref. skripsi [30] - Ramirez - FastAPI

FastAPI

Dipakai untuk: Mendukung fungsi FastAPI sebagai layanan HTTP berbasis Python. Dipakai dalam penjelasan komunikasi antarmuka Android dengan layanan prediksi di komputer lokal.

Sitasi: 14 (PDF 30). **Daftar pustaka:** 59 (PDF 75).

Kuasai saat sidang: Jelaskan alur permintaan SMILES dan respons prediksi; preprocessing RDKit serta inferensi berada pada komputer.

Batas klaim: Endpoint, versi model, kesetaraan skor, dan hasil pengujian harus dibuktikan oleh kode serta catatan uji proyek.

Key BibTeX: ramirez2021

Referensi [31]-[33]

Halaman pada kartu adalah halaman skripsi. Nomor PDF panduan ada pada footer.

Ref. skripsi [31] - Fourches dkk. (2016)

Trust, But Verify II: A Practical Guide to Chemogenomics Data Curation

Dipakai untuk: Mendukung pembedaan penyeragaman penulisan struktur dari perubahan bentuk kimia saat kurasi. Menjadi landasan kehati-hatian pada kanonisasi dan keputusan preprocessing molekul.

Sitasi: 18 (PDF 34). **Daftar pustaka:** 59 (PDF 75).

Kuasai saat sidang: Bedakan kanonisasi, netralisasi muatan, penyeragaman tautomer, dan pengambilan fragmen terbesar.

Batas klaim: Kode skripsi tidak otomatis melakukan seluruh langkah kurasi yang mungkin dibahas dalam literatur.

Key BibTeX: fourches2016

Ref. skripsi [32] - Kensert dkk. (2018)

Evaluating parameters for ligand-based modeling with random forest on sparse data sets

Dipakai untuk: Mendukung dua hal: preseden validasi molekuler dengan lima fold dan lima pengulangan, serta pembahasan panjang fingerprint dan potensi tabrakan hash. Dirujuk pada keputusan validasi dan fitur.

Sitasi: 20 (PDF 36); 21 (PDF 37). **Daftar pustaka:** 59 (PDF 75).

Kuasai saat sidang: Jelaskan kompromi biaya validasi dan mengapa lebih banyak posisi bit dapat mengurangi potensi tabrakan.

Batas klaim: Studi menggunakan Random Forest; bukan bukti lima fold atau 2.048 bit optimal untuk dataset aroma skripsi.

Key BibTeX: kensert2018

Ref. skripsi [33] - Bouthillier dkk. (2021)

Accounting for Variance in Machine Learning Benchmarks

Dipakai untuk: Mendukung pembedaan sumber variasi benchmark, termasuk pembagian data, seed model, dan pencarian parameter. Dipakai untuk membatasi interpretasi variasi skor pada lima pengulangan fold.

Sitasi: 21 (PDF 37). **Daftar pustaka:** 59 (PDF 75).

Kuasai saat sidang: Jelaskan bahwa seed fold berubah tetapi seed model tetap; lima pengulangan menggunakan dataset yang sama.

Batas klaim: Simpangan baku antarseed fold bukan interval kepercayaan dan belum mencakup seluruh sumber variasi penelitian.

Key BibTeX: bouthillier2021